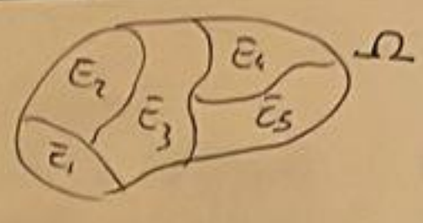
FORMALISMO DELLA TEORIA DELLA PROBABILITÀ



- <u>EVENTO</u> : UNA DELLE POSSIBILI MODALITÀ CON CUI SI PRESENTA L'EVENTO
- <u>SPAZIO CAMPIONARIO</u> : INSIEME DI TUTTI GLI EVENTI
- <u>EVENTI COMPOSTI</u> : DATI DUE EVENTI POSSIAMO DEFINIRE VARIE OPERAZIONI :

- SOMMA LOGICA → $A \cup B$ (L'EVENTO SI MANIFESTA SECONDO A O B) → <u>OR</u>
- PRODOTTO LOGICO → $A \cap B$ (L'EVENTO SI MANIFESTA SE C'È A E B) → <u>AND</u>
- EVENTI INCOMPATIBILI (DISGIUNTI) → $A \cap B = 0$ (IL VERIFICARSI DI UNO IMPLICA IL NON VERIFICARSI DELL'ALTRO)
- EVENTI OPPOSTI (COMPLEMENTARI) → $A \cup B = \Omega$ (EVENTI INCOMPATIBILI LA CUI SOMMA LOGICA FORMA L'INTERO SPAZIO CAMPIONARIO)
- INCLUSIONE → $B \subseteq A$ (TUTTE LE MODALITÀ DI B STANNO IN A) ES: $E_2, E_1 \subseteq (E_2 \cup E_1)$
- CLASSE COMPLETA DI EVENTI → $\begin{cases} \bigcup_{i=1}^{n} E_i = \Omega \\ E_i \cap E_j = 0 \quad \forall i \neq j \end{cases}$ →

PROPRIETÀ : $P(E_i \cup E_j) = P(E_i) + P(E_j)$ IN QUANTO DISGIUNTI

$P(E \cup \bar{E}) = P(E) + P(\bar{E}) = P(\Omega) = 1$

$P(\bigcup_{i=1}^{n} E_i) = P(\Omega) = 1$

IN GENERALE : $P(A \cup B) = P(A) + P(B) - P(B \cap A)$



ASSIOMATICA DELLA PROBABILITÀ

- DEFINIZIONI DI KOLMOGOROV : DATO UNO SPAZIO CAMPIONARIO Ω E UN INSIEME DI EVENTI E_i LA PROBABILITÀ P SODDISFA 3 REGOLE FONDAMENTALI :

1) <u>NON NEGATIVITÀ</u> → $P(E) \geq 0 \quad \forall E \subseteq \Omega$
2) <u>NORMALIZZAZIONE</u> → $P(\Omega) = 1$
3) <u>ADDITIVITÀ</u> → PER DUE EVENTI DISGIUNTI $(A \cap B = 0)$ VALE $P(A \cup B) = P(A) + P(B)$ CON $A, B \subseteq \Omega$

NOTA : DA (1) E (2) DERIVA $0 \leq P(E) \leq 1 \quad \forall E \subseteq \Omega$
$P(0) = 0$ (DALLA (2))

PROBABILITÀ CONDIZIONATA

- UN EVENTO E PUÒ DIPENDERE DALLE CONDIZIONI ESTERNE, PERTANTO È CONDIZIONATO (<u>CONDIZIONANTE</u> H) :

SE E È VERO → H È VERO
SE E È FALSO → H È VERO
SE H È FALSO → E È <u>INDETERMINATO</u>

$$P(E|H) = \frac{\#\text{CASI FAVOREVOLI A } E \text{ E } H}{\#\text{ CASI FAVOREVOLI AD } H}$$

$$\rightarrow P(E|H) = \frac{P(E \cap H)}{P(H)} \quad \text{CON} \quad \begin{cases} H \subset \Omega \\ P(H) \neq 0 \end{cases}$$

NOTA : $P(E|H) \geq P(E \cap H)$

APPROCCIO ONTOLOGICO ED EPISTEMICO ALLA PROBABILITÀ CONDIZIONATA

POSSIAMO RIOTTENERE IL RISULTATO $P(E|H) = \frac{P(E \cap H)}{P(H)}$ PASSANDO PER LA DEF. SOGGETTIVISTA O COMBINATORIA :

<u>COMBINATORIA</u> :

$$P(E|H) = \frac{P(E \cap H)}{P(H)} = \frac{\#E,H}{\#H} = \frac{\#E,H}{\#H} \cdot \frac{\#\Omega}{\#\Omega} = P(E|H)$$

(FAVOREVOLI / POSSIBILI)

<u>RATIONAL BET</u> : DEFINITA LA PUNTATA $A \rightarrow A \propto P(E|H)$, IN PARTICOLARE IL FATTORE DI PROPORZIONALITÀ È L'INSIEME DI TUTTE LE POSSIBILI ALTERNATIVE, PERTANTO → $A = P(E|H)\,S$

→ LA RATIONAL BET HA <u>GUADAGNO ATTESO NULLO</u> PER CUI

SOSTITUISCO A

$$P(G) = \underbrace{(S-A)\,P(E \cap H)}_{\text{VINCITA}} + \underbrace{(-A)P(\bar{E} \cap H)}_{\text{PERDITA}} + \underbrace{(0)(P(\bar{H}))}_{\text{SCOMMESSA ANNULLATA}} = 0 \longrightarrow S\,P(E \cap H) - S\,P(E|H)\,P(H) = 0 \Rightarrow$$

$$\Rightarrow P(E \cap H) = P(E|H)P(H) \Rightarrow P(E|H) = \frac{P(E \cap H)}{P(H)}$$

TEOREMA DELLA PROBABILITÀ COMPOSTA

$$P(E|H) = \frac{P(E \cap H)}{P(H)} \longrightarrow \begin{cases} P(E|H)\,P(H) = P(E \cap H) \\ P(H|E)\,P(E) = P(H \cap E) \end{cases} \xrightarrow{\text{SIMMETRIA}} \frac{P(E|H)}{P(E)} = \frac{P(H|E)}{P(H)}$$

VIZ

DIM (CON RATIONAL BET, MA DIVERSA DA QUELLA PRIMA)

$P(E|H)\,S = A$ MA $S = 1$ (TUTTE LE ALTERNATIVE POSSIBILI) $\rightarrow A = P(E|H)$

$$P(G) = 0 = \underbrace{-A}_{\text{BET}} + \underbrace{S\,P(E \cap H)}_{\text{VINCITA}} + \underbrace{A\,P(\bar{H})}_{\text{SCOM. ANN.}} = -A + SP(E \cap H) + A\,(1 - P(H)) =$$

$$\Rightarrow \cancel{-P(E|H)} + P(E \cap H) + \cancel{P(E|H)} - P(E|H)P(H) = 0 \rightarrow \frac{P(E \cap H)}{P(H)} = P(E|H)\cancel{P(H)} \quad \text{c.v.d.}$$

EVENTI INDIPENDENTI IN PROBABILITÀ

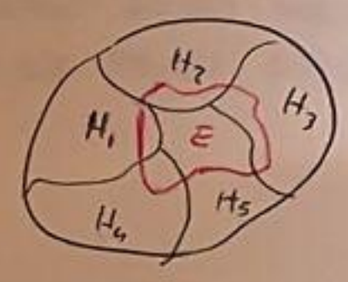
$P(E|H) = P(E) \rightarrow$ E ED H SONO INDIPENDENTI IN PROBABILITÀ, CIOÈ IL VERIFICARSI DI UNO NON IMPLICA NULLA SUL VERIFICARSI DELL'ALTRO.

$P(E \cap H) = P(E|H)P(H) = P(E)P(H)$ SE E ED H SONO IND. IN PROB.

$P(E_1 \cap \dots \cap E_n) = \prod_{i=1}^{n} P(E_i)$ SE GLI EVENTI E_i SONO INDIPENDENTI IN PROBABILITÀ

LEGGE DELLE ALTERNATIVE E TEOREMA DI BAYES

ABBIAMO UNA CLASSE COMPLETA DI IPOTESI H_i: $\begin{cases} \bigcup_{i=1}^{n} H_i = \Omega \\ H_i \cap H_j = 0 \quad \forall i \neq j \end{cases}$



$$E = \bigcup_{i=1}^{n} (E \cap H_i) \rightarrow P(E) = \sum_{i=1}^{n} P(E \cap H_i) \quad \text{MA} \quad \sum_{i=1}^{n} P(H_i) = 1 \quad \text{PER CUI}$$

(COMB. LINEARE DI H_i)

$$P(E) = \frac{\sum_{i=1}^{n} P(E \cap H_i)}{\sum_{i=1}^{n} P(H_i)} \overset{\text{T}^{\text{a}} \text{ PROB. COMPOSTA}}{=} \frac{\sum_{i=1}^{n} P(E|H_i)\,P(H_i)}{\sum_{i=1}^{n} P(H_i) = 1} \rightarrow \left(\begin{array}{c}\text{LEGGE DELLE} \\ \text{ALTERNATIVE}\end{array}\right)$$

DOVE

VOGLIAMO FARE INFERENZA SULL'IPOTESI i-ESIMA:

$$P(E \cap H_i) = P(E|H_i)P(H_i) \qquad P(E \cap H_i) = P(H_i \cap E) = P(H_i|E)P(E)$$

$$\rightarrow P(E|H_i)\,P(H_i) = P(H_i|E)\,P(E) \rightarrow P(H_i|E) = \frac{P(E|H_i)\,P(H_i)}{P(E)} \rightarrow$$

LEGGE DELLE ALT. ↑

$$\rightarrow P(H_i|E) = \frac{P(E|H_i)\,P(H_i)}{\sum_{i=1}^{n} P(E|H_i)\,P(H_i)} \rightarrow \left(\begin{array}{c}\text{T}^{\text{a}} \text{ DI BAYES} \\ \text{PER L'INFERENZA}\end{array}\right)$$

MISURA DI UNA GRANDEZZA FISICA

DEF

RIPETIBILITÀ: SONO IN CONDIZIONI DI RIPETIBILITÀ QUANDO POSSO RIPETERE LE MISURE SENZA CHE CAMBINO LE CONDIZIONI CHE POSSONO ALTERARE IL RISULTATO (OPERATORE, STRUMENTO, COND. AMBIENTALI ...)

RIPRODUCIBILITÀ: SI VERIFICA QUANDO PIÙ ESPERIMENTI RIPORTANO LO STESSO RISULTATO; È LA CONDIZIONE NECESSARIA PER ACCETTARE UN RISULTATO

PROBABILITÀ

PER DEFINIRE LA PROBABILITÀ, CI SONO 2 APPROCCI:

- ONTOLOGICO: TRATTA LA PROBABILITÀ COME UNA PROPRIETÀ INTRINSECA DEL FENOMENO, CHE PUÒ PRESENTARSI IN DIVERSE MODALITÀ.

- EPISTEMICO: TRATTA LA PROBABILITÀ COME UN VALORE CHE NOI ASSOCIAMO AD UN FENOMENO, SULLA BASE DELLE NOSTRE CONOSCENZE (STATO DI INFORMAZIONE) SU COME SI MANIFESTA IL FENOMENO. ⇒ CON QUESTO APPROCCIO LA PROBABILITÀ NON È ASSOLUTA MA DIPENDE DALL'OSSERVATORE E DAL SUO "GRADO DI FIDUCIA" (DEGREE OF BELIEF) $\in [0,1]$

CALCOLO DELLE PROBABILITÀ

→ LE DUE DEFINIZIONI PORTANO A DUE VIE DIFFERENTI PER IL CALCOLO DELLA PROBABILITÀ:

- COMBINATORIO (LAPLACE) → $P(E) = \frac{\#\text{CASI FAVOREVOLI AD } E}{\#\text{CASI EQUIPROBABILI TOTALI}}$

→ L'EQUIPROBABILITÀ DEGLI EVENTI ELEMENTARI $\{e_i\}$ È IL GRANDE LIMITE DI QUESTA DEFINIZIONE INOLTRE È UNA DEF. CIRCOLARE (PER DEFINIRE LA PROBABILITÀ USA IL CONCETTO DI PROBABILITÀ)

- FREQUENTISTA ⟶ $P(E) = \lim_{n \to \infty} \frac{\#\text{SUCCESSI}}{\#\text{PROVE}}$ ($\#\text{PROVE} = n$) ⇒ FREQ. RELATIVA DI SUCCESSO

→ TALE APPROCCIO RICHIEDE (IN LINEA DI PRINCIPIO) CHE L'ESPERIMENTO SIA RIPETIBILE QUANTE VOLTE NELLE STESSE CONDIZIONI. INOLTRE VALE SOLO DOPO AVER FATTO L'ESPERIMENTO.

⇒ DA QUESTE DUE VIE POSSIAMO RICAVARE LA MIGLIOR DEFINIZIONE DI PROBABILITÀ:

- APPROCCIO SOGGETTIVISTA: ASSUMENDO UN CERTO STATO DI INFORMAZIONE (NECESSARIO) DEFINIAMO LA SCOMMESSA RAZIONALE (RATIONAL BET) → SUPPONIAMO DI VOLER SCOMMETTERE X PER VINCERE Y NEL CASO SI VERIFICHI UN CERTO EVENTO:

$\begin{cases} X \text{ PUNTATA} \\ Y \text{ VINCITA} \\ E \text{ EVENTO} \end{cases}$ $X \propto P(E)$ E $X \propto Y$ → $X = P(E)Y$ → $P(E) = \frac{X}{Y}$ (SE CREDO MOLTO POCO CHE SI VERIFICHI E $X \ll Y$ PER CUI $P(E) \to 0$)

. SICCOME $0 \le P(E) \le 1$ ALLORA $X \le Y$

VALORE ATTESO / ASPETTATO

DEF : PREVISIONE : PARAMETRO CHE INDICA IL VALORE INTORNO AL QUALE POSSA RAGIONEVOLMENTE VERIFICARSI LA V.C.

INCERTEZZA : LA DISPERSIONE DEI VALORI ASSUNTI DALLA V.C. (QUANTO I DATI OSCILLANO INTORNO LA PREVISIONE)

VALORE ATTESO : $E[X] = \sum_i x_i f(x_i)$ = SOMMA DI TUTTI I VALORI CHE PUÒ ASSUMERE LA V.C. MOLTIPLICATI PER LA LORO PROBABILITÀ. NOTA : IL VALORE ATTESO È DIVERSO DALLA MEDIA, IN QUANTO SUO ESPRIMENDO LA TENDENZA CENTRALE : È COME SE STESSI FACENDO UNA MEDIA PESATA DEI VALORI POSSIBILI DI UNA QUANTITÀ:

$$E[X] = \mu = \frac{\sum_i x_i f(x_i)}{\sum_i f(x_i) = 1}$$

- SE LA DISTR. FOSSE SIMMETRICA MODA, MEDIA E PREVISIONE CORRISPONDEREBBERO

PROP : $E[aX+b] = \sum_i (ax_i + b) f(x_i) = \sum_i a x_i f(x_i) + \sum_i b f(x_i) = a E[X] + b$ (IL VAL. ATTESO È UN OPERATORE LINEARE), LA

VARIANZA E DEV. STANDARD

- IL VALORE ATTESO CI DICE ~~[illegible]~~ IL VALORE INTORNO AL QUALE CREDIAMO SI REALIZZERÀ, MA NOI VOGLIAMO ANCHE CAPIRE LO SPREAD (LA LARGHEZZA DELLA DISTR.) DEI DATI. PER MISURARE TALE LARGHEZZA SI DEFINISCE LA VARIANZA, OVVERO LO SCARTO QUADRATICO TRA I DATI E IL VALORE ATTESO :

$$\sigma^2[X] = VAR[X] = E[(X-\mu)^2]$$ → APPLICANDO LA LINEARITÀ DEL VALORE ASPETTATO SI OTTIENE:

$$\sigma^2[X] = E[X^2 + \mu^2 - 2\mu X] = E[X^2] + \mu^2 - 2\mu E[X] = E[X^2] + \mu^2 - 2\mu^2 =$$

$$= E[X^2] - E[X]^2 \rightarrow VAR[X] = E[X^2] - E[X]^2$$

PROP : $\sigma^2(aX+b) = E\left[[(aX+b) - E[aX+b]]^2\right] = E\left[[aX+b - aE[X] - b]^2\right] =$

$$= E\left[a^2 (X - E[X])^2\right] = a^2 VAR[X]$$ (LA VARIANZA È UN OPERATORE QUADRATICO)

$\sigma(X)$ = DEV. STAND. = $\sqrt{\sigma^2(X)}$

VAR. CASUALI CONTINUE

- NEL CASO CONTINUO, LA VAR. CAS. PUÒ ASSUMERE INFINITI VALORI → $(P(X = x_i) \rightarrow 0)$ PERTANTO CONSIDERIAMO LA PROBABILITÀ (CUMULATIVA) $P(a \le X \le b)$ CHE LA MISURA CADA IN UN CERTO INTERVALLO, DEFINENDO UN "CONFIDENCE BALANCE". RIDUCENDO L'INTERVALLO AD UN ELEMENTO INFINITESIMO dx ALLORA LA PROB. INFINITESIMA $dP \propto f(x)\,dx$. PER TROVARE LA PROB. TOTALE NELL'INTERVALLO $[a,b]$, LA SOMMATORIA SI TRASFORMA IN UN INTEGRALE → $P(a \le X \le b) = \int_a^b f(x)\,dx = F(b) - F(a)$

SICCOME $F(x) = P(X \le x) = \int_{-\infty}^{x} f(x')\,dx' \rightarrow f(x) = \frac{dF(x)}{dx}$ PER CUI LA DERIVATA DELLA FUNZIONE DI RIPARTIZIONE È LA FUNZIONE DENSITÀ DI PROBABILITÀ.

POSSIAMO QUINDI DEFINIRE VALORE ASPETTATO E VARIANZA ANCHE NEL CASO CONTINUO:

$$\mu = E[x] = \int_{-\infty}^{+\infty} x f(x)\,dx \qquad \sigma^2 = VAR[x] = \int_{-\infty}^{+\infty} (x-\mu)^2 f(x)\,dx$$

VARIABILI CASUALI MULTIPLE

- PER PIÙ VARIABILI (ES: 2) SI OTTIENE CHE $f(x,y) = P(\overline{X}=x, \overline{Y}=y) = P(x \cap y)$ → [PROBABILITÀ CHE AVVENGANO SIA x SIA y INSIEME]

→ QUESTA PDF È DETTA CONGIUNTA E PER DEF. DI PDF VALE: $\sum_{i,j} P(\overline{X}=x_i ; \overline{Y}=y_j) = \sum_{i,j} f(x_i, y_j) = 1$ (NORMALIZZ.)

→ LA FUNZIONE DI RIPARTIZIONE SI DEFINISCE $F(x_k, y_\ell) = P(\overline{X} \le x_k ; \overline{Y} \le y_\ell) = \sum_{\substack{x_i \le x_k \\ y_s \le y_\ell}} f(x_i, y_s) = F(x,y)$

PROP. $F(x,y)$: 1) $F(x,y)$ È NON DECRESCENTE

2) $F(x,y) \to 0$ PER $(x \to -\infty, y \to -\infty)$ E $F(x,y) \to 1$ PER $(x \to +\infty, y \to +\infty)$

3) $F(x_i; y_j) - F(x_{i-1}; y_{s-1}) = f(x_i, y_s)$

→ STUDIO IL VERIFICARSI DI $\overline{X} = x_i$ SE $\overline{Y} = y_s$ SI È VERIFICATO, PERTANTO USIAMO LA DEFINIZIONE DI PROBABILITÀ CONDIZIONATA:

$$P(\overline{X}=x_i \mid \overline{Y}=y_s) = f(x|y) \xrightarrow{\text{BAYES}} f(y|x) = \frac{f(x|y)\, f(y)}{\sum_i f(x_i|y_i)\, f(y_i)}$$

CASO CONTINUO: $F(x,y) = P(\overline{X} \le x ; \overline{Y} \le y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f(x';y')\,dx'dy'$ PERTANTO VALE CHE

$dF(x,y) = f(x,y)\,dx\,dy \Rightarrow f(x,y) = \dfrac{\partial^2 F(x,y)}{\partial x\, \partial y}$ MENTRE SE INTEGRO IN UNA DELLE DUE VAR:

$f_X(x) = \int_{-\infty}^{+\infty} f(x,y)\,dy$ OPPURE $f_Y(y) = \int_{-\infty}^{+\infty} f(x,y)\,dx$ → DENSITÀ DI PROB. MARGINALE

APPLICANDO ORA IL TEOREMA DI BAYES: ($P(A|B) = \frac{P(A \cap B)}{P(B)}$)

$$P(x \le \overline{X} \le x+dx \mid \overline{Y}=y) = \frac{P[(x \le \overline{X} \le x+dx) ; (y \le \overline{Y} \le y+dy)]}{P(y \le \overline{Y} \le y+dy)} \Rightarrow$$

$$\Rightarrow f(x|y)\,dx = \frac{f(x,y)\,dx\,dy}{f(y)\,dy} \Rightarrow f(x|y) = \frac{f(x,y)}{f(y)} = \frac{f(x,y)}{\int_{-\infty}^{+\infty} f(x,y)\,dx}$$ E SICCOME

$f(x,y) = f(x|y)f(y) = f(y|x)\,f(x) = f(y,x)$ A MENTE $\dfrac{f(x)}{f(y)} = \dfrac{f(x|y)}{f(y|x)}$ PER CUI

$$f(x|y) = \frac{f(x)\,f(y|x)}{f(y)} = \frac{f(y|x)\,f(x)}{\int_{-\infty}^{+\infty} f(y|x)\,f(x)\,dy}$$

A COSA SERVE BAYES? CONFRONTO IPOTESI ALLA LUCE DI DATI RACCOLTI E CONOSCENZE PREGRESSE

IN PARTICOLARE: $\underbrace{f(\mu|x)}_{\text{POSTERIOR}} = \frac{\mathcal{L}(x|\mu)\, f_0(\mu)}{\sum_i \mathcal{L}(x|\mu_i)\, f_0(\mu_i)}$

DOVE
- $\mathcal{L}$:= LIKELIHOOD (VEROSIMIGLIANZA), DATA DAI RISULTATI DELL'ESPERIMENTO.
- f_0 := PRIOR, OVVERO LA NOSTRA CONOSCENZA A PRIORI.

- LA LIKELIHOOD RAPPRESENTA LA PROBABILITÀ DI OSSERVARE X A CONDIZIONE CHE SIA STATO GENERATO DA μ

NOTIAMO CHE $P(H_i|E) \propto P(E|H_i)P(H_i)$ CIOÈ (POSTERIOR) $\propto$ (LIKELIHOOD)(PRIOR) → PER CONFRONTARE DUE IPOTESI E SCEGLIERE LA PIÙ ADEGUATA SI STUDIA IL RAPPORTO TRA LE POSTERIOR.

$$\frac{P(H_i|E)}{P(H_j|E)} = \frac{P(E|H_i)P(H_i)}{P(E|H_j)P(H_j)} = \frac{P(E|H_i)}{P(E|H_j)} \cdot \frac{P(H_i)}{P(H_j)} = \mathcal{L}_r \cdot F_0$$ DOVE

$\mathcal{L}_r$:= LIKELIHOOD RATIO / BAYES FACTOR F_0 := ODDS A PRIORI (NON TRASCURABILE)

→ (POSTERIOR ODDS) = (BAYES FACTOR)(PRIOR ODDS), QUINDI:

- POST. ODDS > 1 → H_i PIÙ AFFIDABILE
- POST ODDS < 1 → H_j PIÙ AFFIDABILE

NOTA: NON VIENE MAI TRASCURATA LA PRIOR IN FAVORE DEI DATI SPERIMENTALI "NUOVI". INFATTI VIENE SEMPRE MOLTIPLICATO IL BAYES FACTO PER LE PRIOR ODDS

VARIABILI CASUALI

- DEF: UNA VAR. CASUALE È UNA MODALITÀ CON CUI PUÒ AVVENIRE UN EVENTO, LEGATO ALL'OCCORRENZA DI UN NUMERO RISPETTO ALLA MOLTEPLICITÀ DI NUMERI POSSIBILI → IL RISULTATO DI UNA MISURA CORRISPONDE QUINDI AD UNA VAR. CASUALE.

PER "CASUALE" NON SI INTENDE "A CASO", MA SIGNIFICA CHE ESSA ASSUME VALORI CON CERTE CARATTERISTICHE (SEGUE LEGGI PROBABILISTICHE) NONOSTANTE NON SIA POSSIBILE DETERMINARE CON ASSOLUTA CERTEZZA IL RISULTATO DELL'EVENTO.

- SE $X \in \mathbb{R}$ → LA VAR. CAS. È CONTINUA → ES: MISURA INTERVALLO TEMPO
- SE $X \in \mathbb{N} \vee \mathbb{Q}$ → LA VAR. CAS. È DISCRETA → ES: IMPULSI CONTATORE GEIGER

DISTRIBUZIONI DI PROBABILITÀ

- LA DISTRIBUZIONE DI PROB. È LA FUNZIONE CHE INDICA LA PROBABILITÀ CHE ASSOCIAMO AD OGNI EVENTO POSSIBILE

$$\boxed{P(X=x) = f(x)}$$

PROPRIETÀ:
-) $0 \le f(x) \le 1 \quad \forall x$
-) $P(X=x_i \cup X=x_j) = P(X=x_i) + P(X=x_j) = f(x_i) + f(x_j)$
-) $\sum_i f(x_i) = 1$ PERCHÉ $\bigcup_i x_i = \Omega$

- LA FUNZIONE DI RIPARTIZIONE DESCRIVE LA PROBABILITÀ CUMULATIVA, CIOÈ:

$$F(x_k) = P(X \le x_k) = f(x_1) + f(x_2) + \dots + f(x_k) = \sum_{i \le k} f(x_i)$$

PROPRIETÀ:
-) $0 \le F(x) \le 1$
-) $F(x_i) - F(x_i - 1) = f(x_i)$
-) $\lim_{x \to +\infty} F(x) = 1$
-) $\lim_{x \to -\infty} F(x) = 0$

DISTRIBUZIONI DI VARIABILI CASUALI

- UNA V.C. SI PUÒ DISTRIBUIRE SECONDO UNA FUNZIONE DETTA "PROBABILITY DENSITY FUNCTION" (PDF), CHE PUÒ ESSERE DI TIPO: GAUSSIANA, UNIFORME, BINOMIALE, POISSONIANA, GAMMA, χ^2 ...

SUPPONIAMO DI AVERE $X \sim \overbrace{f_X(X)}^{PDF(X)}$. DEFINIAMO $y = g(x)$ CRESCENTE MONOTONA (CI APPROSSIMIAMO AD INTERVALLI IN CUI VALE LA MONOTONIA) $\rightarrow X = g^{-1}(y)$

$\rightarrow$ CONSIDERIAMO ALLORA $dP(x \leq X \leq x+dx) = dP(y \leq Y \leq y+dy) \Leftrightarrow f_y(y)\,dy = f_x(x)\,dx$

$$\rightarrow f_y(y) = f_x(x)\frac{dx}{dy} \rightarrow \frac{f_x(x)}{\left(\frac{dy}{dx}\right)} = f_y(y) \rightarrow \frac{f_x(x)}{g'(x)} = f_y(y)$$

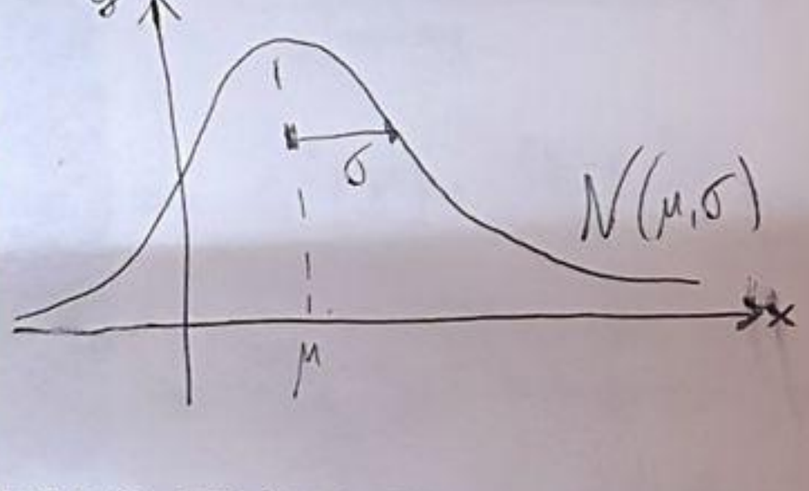
- SICCHÉ $x = g^{-1}(y)$ (LA MONOTONIA SERVE PER ASSICURARCI CHE g SIA INVERTIBILE)

$$\Rightarrow f_y(y) = \frac{f_x\left(g^{-1}(y)\right)}{g'\left(g^{-1}(y)\right)} \rightarrow$$ ABBIAMO QUINDI LA PDF DI y $\rightarrow PDF(y) = \left|\frac{dx(y)}{dy}\right| f(x(y))$

GAUSSIANA / NORMALE

$$N(\mu_x, \sigma_x) = f(x) = \frac{1}{\sigma_x\sqrt{2\pi}}\, e^{-\frac{1}{2}\left[\frac{(x-\mu_x)}{\sigma_x}\right]^2}$$

DOVE $\frac{1}{\sigma_x\sqrt{2\pi}}$ È IL FATTORE DI NORMALIZZAZIONE



CARATTERISTICHE:

- SIMMETRICA RISPETTO μ: $f(\mu+x) = f(\mu-x)$
- MODA ≡ MEDIA ≡ MEDIANA
- IL MASSIMO VALE $f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$
- 2 PT. DI FLESSO $\rightarrow \mu-\sigma$ E $\mu+\sigma$
- DOMINIO $\rightarrow x \in \mathbb{R}$

NORMALE STANDARDIZZATA

DATA $N(\mu, \sigma)$ $\rightarrow$ DEFINIAMO UNA PDF t.c. $z = \frac{X-\mu}{\sigma}$, OSSIA UNA NORMALIZZAZIONE DI N, SI OTTIENE QUINDI UNA GAUSSIANA CON PARAMETRI:

$$E[z] = E\left[\frac{x}{\sigma_x} - \frac{\mu}{\sigma_x}\right] = \frac{1}{\sigma_x}E[x] - \frac{\mu}{\sigma_x} = 0$$

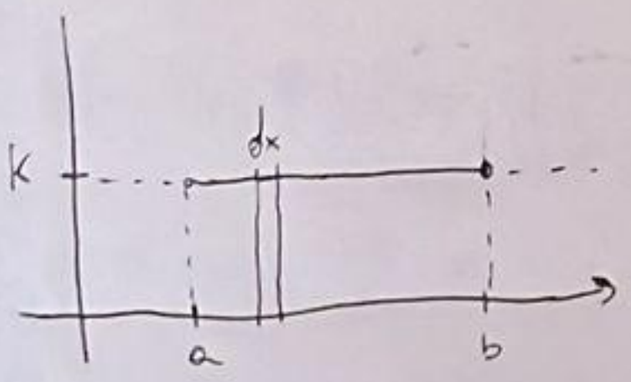
$$VAR[z] = VAR\left[\frac{x-\mu}{\sigma_x}\right] = \frac{1}{\sigma_x^2}VAR[x-\mu] = \frac{1}{\sigma_x^2}E[(x-\mu)^2] = 1$$

$z \sim N(0,1)$

NORMALE MULTIVARIATA

DISTRIBUZIONE UNIFORME

- TUTTI I VALORI DELLA VAR. CAS. HANNO STESSA PROB. DI ESSERE OTTENUTI



$$f(x) = \begin{cases} k & \text{SE } a \le x \le b \\ 0 & \text{SE } (x>b) \cup (x<a) \end{cases}$$

NORMALIZZ

$$\int_{-\infty}^{+\infty} f(x)\,dx = \int_a^b k\,dx = k(b-a) = 1 \quad \Rightarrow \quad k = \frac{1}{b-a} = f(x) \quad \text{(PDF)} \quad \Rightarrow \quad X \sim f(x) = \frac{1}{b-a}$$

$$E[X] = \int_{-\infty}^{+\infty} x f(x)\,dx = \int_a^b \frac{x}{b-a}\,dx = \frac{1}{b-a}\,\frac{x^2}{2}\Big|_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{b+a}{2}$$

$$VAR[X] = \int_a^b (x - E[X])^2 \frac{1}{b-a}\,dx = \int_{a-E[x]}^{b-E[x]} t^2 \frac{1}{b-a}\,dt = \frac{t^3}{3(b-a)}\Big|_{a-E[x]}^{b-E[x]} =$$

$$x - E[x] = t$$

$$= \frac{\left(b - \frac{b+a}{2}\right)^3 - \left(a - \frac{b+a}{2}\right)^3}{3(b-a)} = \frac{\left(\frac{b-a}{2}\right)^3 - \left(\frac{a-b}{2}\right)^3}{3(b-a)} = \frac{(b-a)^3 - (a-b)^3}{24(b-a)} = \frac{2(b-a)^2}{24}$$

$$\Rightarrow \sigma^2(X) = \frac{(b-a)^2}{12} \quad \Rightarrow \quad \sigma(x) = \frac{|b-a|}{\sqrt{12}}$$

SOMMA E DIFFERENZA DI VAR. CASUALI

CONSIDERO $Z = X \pm Y$ V.C. CONTINUA, PERTANTO OTTENIAMO CHE:

RICORDA: $\int_{-\infty}^{+\infty} f(x,y)\,dy = f(x)$ (E VICEVERSA)

$$E[Z] = \int_{-\infty}^{+\infty}\int (x \pm y) f(x,y)\,dx\,dy = \int_{-\infty}^{+\infty}\int x f(x,y)\,dx\,dy \pm \int_{-\infty}^{+\infty}\int y f(x,y)\,dx\,dy = \int_{-\infty}^{+\infty} x f(x)\,dx \pm \int_{-\infty}^{+\infty} y f(y)\,dy = E[x] \pm E[y]$$

$$VAR[Z] = E\left[\left((x \pm y) - E[x \pm y]\right)^2\right] = E\left[\left((x - E[x]) \pm (y - E[y])\right)^2\right] = E\left[(x-E[x])^2 + (y-E[y])^2 \pm 2(x-E[x])(y-E[y])\right] =$$

$$\Rightarrow \sigma^2(Z) = \sigma^2(x) + \sigma^2(y) \pm 2\,cov(x,y) \quad \Rightarrow \quad \sigma^2(Z) = \sigma_x^2 + \sigma_y^2 \quad \Rightarrow \quad \underline{\sigma_Z = \sqrt{\sigma_x^2 + \sigma_y^2}}$$

(x, y INDIP.)

DATA UNA FUNZIONE DI n VARIABILI (COMB. LINEARE) COME TROVO μ_y E σ_y^2:

$$y = a_1 x_1 + b x_2 \ldots + c \quad \Rightarrow \quad \begin{cases} E[y] = \mu_y = a\mu_1 + b\mu_2 \ldots + c \\ VAR[y] = \sigma_y^2 = a^2\sigma_x^2 + b^2\sigma_y^2 + 2ab\,\underbrace{cov(x,y)}_{\rho_{xy}\sigma_x\sigma_y} \end{cases}$$

$$y = \sum_i a_i x_i \quad \Rightarrow \quad \begin{cases} E[Y] = \sum_i a_i \mu_i \\ VAR[Y] = \sum_i a_i^2 \sigma_i^2 + 2\sum_{i<j}^{n} a_i a_j \sigma_{ij} \end{cases}$$

PROPAGAZIONE DELLE INCERTEZZE

- SUPPONIAMO DI AVERE UNA PDF CONG. LINEARE DI n VAR. CAS. → UTILIZZIAMO LO SVILUPPO IN SERIE DI TAYLOR PER RICONDURLA AD UN OGGETTO PIÙ SEMPLICE — → LINEARIZZAZIONE

$$y(x_1 \dots x_n) \cong y(\mu_1 \dots \mu_n) + \sum_i \left(\frac{\partial y}{\partial x_i}\right)\Big|_{\mu_i} (x_i - \mu_i) + o\left((x_i - \mu_i)^2\right)$$

$$y \simeq k + \sum_{i=1}^{n} \alpha_i x_i \quad \text{DOVE} : \begin{cases} k = y(\mu_1 \dots \mu_n) + \sum_{i=1}^{n} \left(\frac{\partial y}{\partial x_i}\right)\Big|_{\mu_i} \mu_i \\ \alpha_i = \left(\frac{\partial y}{\partial x_i}\right)\Big|_{\mu_i} \end{cases}$$

$$VAR(y) = \sum_{i,j}^{1,n} \alpha_i \alpha_j \sigma_{ij} = \sum_{i,j}^{1,n} \left(\frac{\partial y}{\partial x_i}\right)\left(\frac{\partial y}{\partial x_j}\right)\Big|_{\mu_i} \sigma_{ij} = \sum_{i=1}^{n} \left(\frac{\partial y}{\partial x_i}\right)\Big|_{\mu_i}^2 \sigma_i^2 + 2 \sum_{i<j}^{1,n} \left(\frac{\partial y}{\partial x_i}\right)\left(\frac{\partial y}{\partial x_j}\right)\Big|_{\mu_i} \sigma_{ij}$$

SE LE VAR. SONO TUTTE INDIP. IL SECONDO TERMINE (COVARIANZE) È NULLO

QUINDI : $\sigma^2(y) = \sum_{i=1}^{n} \left(\frac{\partial y}{\partial x_i}\Big|_{\mu_i}\right)^2 \sigma_i^2$ IN QUANTO $\sigma_{ij} = 0 \quad \forall i \neq j$

FUNZIONI MONOMIE DI n VAR. INDIPENDENTI

CONSIDERIAMO $y(x_1 \dots x_n) = \prod_i^n x_i^{\alpha_i}$

$$\sigma^2(y) = \sum_i \left(\frac{\partial y}{\partial x_i}\Big|_{\mu_i}\right)^2 \sigma_i^2 = \sum_i \left(\frac{\partial \prod_i x_i^{\alpha_i}}{\partial x_i}\Big|_{\mu_i}\right)^2 \sigma_i^2 = \sum_i \left[\alpha_i x^{\alpha_i - 1} \prod_{j \neq i} x_j^{\alpha_j}\Big|_{\mu_i}\right]^2 \sigma_i^2 =$$

$$\sum_i \left[\frac{\alpha_i}{x_i} \prod_j x_j^{\alpha_j}\Big|_{\mu_i}\right]^2 \sigma_i^2 = \sum_i \left[\frac{\alpha_i}{x_i} y\right]_{\mu_i}^2 \sigma_i^2 = y^2 \sum_i \left(\frac{\alpha_i}{x_i}\right)^2 \sigma_i^2\Big|_{\mu_i}$$

$$\Rightarrow \frac{\sigma_y^2}{y^2} = \sum_i \left(\frac{\alpha_i}{x_i}\right)^2 \sigma_i^2\Big|_{\mu_i} \Rightarrow \frac{\sigma_y}{y} = \sqrt{\sum_i \left(\frac{\alpha_i}{x_i}\right)^2 \sigma_i^2}\Big|_{\mu_i}$$

INCERTEZZA DELLA MEDIA DI VARIABILI ANALOGHE

DEF : n VARIABILI SI DICONO ANALOGHE SE SI DISTRIBUISCONO ALLO STESSO MODO (CON UGUALI $E[x]$ E $\mathrm{var}[x]$) PER CUI :

.) $E[x_i] = \mu \quad \forall i$.) $\sigma^2[x_i] = \sigma^2 \quad \forall i$.) $x_i \sim f(x_i) = f(x) \quad \forall i$

- SOTTO L'IPOTESI DI UNA SERIE DI PROVE IN COND. DI RIPETIBILITÀ DEFINISCO LA MEDIA CAMPIONARIA

$$\bar{X} = \frac{1}{n} \sum_i^n x_i \Rightarrow \begin{cases} E[\bar{x}] = E\left[\frac{1}{n}\sum x_i\right] = \frac{1}{n}\sum \mu_i = \frac{n}{n}\mu = \mu \\ VAR[\bar{x}] = VAR\left[\frac{1}{n}\sum x_i\right] = \frac{1}{n^2}\sum \sigma_i^2 = \frac{1}{n^2} n \sigma_0^2 = \frac{\sigma^2}{n} \end{cases} \rightarrow \begin{cases} E[\bar{x}] = \mu \\ \sigma[\bar{x}] = \frac{\sigma}{\sqrt{n}} \end{cases}$$

= SICCOME NON CONOSCO σ A PRIORI, HO BISOGNO DI UN QUANTIFICATORE CHE INDICHI LA DISPERSIONE DELLA SINGOLA MISURA RISPETTO ALLA MIGLIOR STIMA → VARIANZA CAMPIONARIA

$$s_{n-1}^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$$

- DIVISIONE PER $n-1$ PERCHÉ DEVO TOGLIERE UN GDL ($\bar{x}$)
- POSSO DEFINIRE $E[S_{n-1}^2]$ E $VAR[S_{n-1}^2]$ IN QUANTO È UNA VAR. CAMPIONARIA → $VAR[S_{n-1}^2] = \frac{2\sigma^4[x]}{n-1}$

$$E[S_{n-1}^2] = E\left[\frac{1}{n-1}\sum (x_i - \bar{x})^2\right] = \frac{1}{n-1} E\left[\sum (x_i - \mu + \mu - \bar{x})^2\right] = \frac{1}{n-1} E\left[\sum (x_i - \mu)^2 + \sum (\mu - \bar{x})^2 + 2\sum (x_i - \mu)(\mu - \bar{x})\right] =$$

$$= \frac{1}{n-1}\left(n\sigma^2(x) + n\frac{\sigma^2(x)}{n} + 2\sum E\left[(x_i - \mu)(\bar{x} - \mu)\right]\right) = \frac{1}{n-1}\left(n\sigma^2(x) + \sigma^2(x) + 2E\left[(\mu - \bar{x})\sum (x_i - \mu)\right]\right) = \frac{1}{n-1}\left((n+1)\sigma_x^2 + \underbrace{2E\left[(\mu - \bar{x})(n\bar{x} - n\mu)\right]}_{-2nE[(\bar{x}-\mu)^2]}\right) = \frac{1}{n-1}\left((n+1)\sigma_x^2 - 2n\frac{\sigma^2}{n}\right) = \sigma_x^2$$

COVARIANZA

- LE DUE VARIABILI RISULTANO LEGATE L'UNA ALL'ALTRA INFATTI:

$$E[x] = \int_{-\infty}^{+\infty}\int x\, f(x,y)\, dx\, dy \qquad E[y] = \int_{-\infty}^{+\infty}\int y\, f(x,y)\, dx\, dy$$

$$\sigma^2[x] = \int_{-\infty}^{+\infty}\int (x-E[x])^2 f(x,y)\, dx\, dy \qquad \sigma^2[y] = \int_{-\infty}^{+\infty}\int (y-E[y])^2 f(x,y)\, dx\, dy$$

SE LE DUE VARIABILI SONO INDIPENDENTI LA PDF FATTORIZZA: $f(x,y) = f(x)\, f(y)$

POSSIAMO QUINDI DEFINIRE UNA NUOVA QUANTITÀ, LA COVARIANZA, CHE INDICA COME LE DUE VARIABILI TENDONO A VARIARE INSIEME. IN PARTICOLARE:

$$cov[x,y] = \int_{-\infty}^{+\infty}\int (x-E[x])(y-E[y])\, f(x,y)\, dx\, dy \qquad \text{DISCRETO: } E[(x-\mu_x)(y-\mu_y)] = cov(x,y)$$

SE DUE VAR. SONO INDIPENDENTI, ALLORA $cov(x,y) = 0$ (PERCHÉ LA PDF FATTORIZZA)

$$\begin{cases} cov(x,y) = cov(y,x) \\ cov(x,x) = VAR(x) = \sigma^2(x) \end{cases}$$

→ PER CAPIRE IN MODO DIRETTO QUANTO LE DUE VARIABILI SIANO CORRELATE, INTRODUCIAMO IL COEFFICIENTE DI CORRELAZIONE LINEARE:

$$\rho(x,y) = \frac{cov(x,y)}{\sigma(x)\,\sigma(y)} \quad [\text{adim.}] \qquad -1 \le \rho \le 1 \rightarrow \begin{cases} \rho = 1 \rightarrow \text{CORREL. LINEARE POSITIVA} \\ \rho = -1 \rightarrow \text{CORREL. LINEARE NEGATIVA} \\ \rho = 0 \rightarrow \text{NO CORRELAZIONE } \underline{\text{LINEARE}} \text{ !!!} \\ \qquad (\text{POTREBBE ESSERE NON LIN.}) \end{cases}$$

$$cov(x,y) = E[(x-\mu_x)(y-\mu_y)] = E[xy - \mu_x y - \mu_y x + \mu_x\mu_y] = E[xy] - E[x]E[y] - E[y]E[x] + E[x]E[y]$$

$$\rightarrow cov(x,y) = E[xy] - E[x]E[y] \qquad \text{DOVE } E[xy] = \int_{-\infty}^{+\infty}\int xy\, f(x,y)\, dx\, dy$$

- $y = ax+b$
- $E[y] = aE[x]+b = a\mu_x + b$
- $\sigma^2[y] = a^2\sigma^2(x) \rightarrow \sigma(y) = |a|\,\sigma(x)$
- $cov(x,y) = E[(x-\mu_x)(ax+b-a\mu_x-b)] = E[a(x-\mu_x)^2] = aE[(x-\mu_x)^2] = a\sigma^2(x)$

$$\rightarrow \rho(x,y) = \frac{cov(x,y)}{\sigma(x)\,\sigma(y)} = \frac{a\sigma^2(x)}{\sigma(x)\,|a|\,\sigma(x)} = sign(a) = \pm 1$$

IN GENERALE (n VARIABILI) HO BISOGNO DI $N = n + \frac{n(n-1)}{2} = \frac{n(n+1)}{2}$ VALORI (INDIPENDENTI) PER ESPRIMERE LE INCERTEZZE (ES: CON 2 VARIABILI MI SERVONO $\sigma_x, \sigma_y, cov(x,y)$) → PER UNA RAPPRESENTAZIONE COMODA SI UTILIZZA UNA MATRICE QUADRATA SIMMETRICA DI $dim = N$ DOVE SULLA DIAGONALE TROVIAMO LE VARIANZE DELLE SINGOLE VAR. CASUALI MENTRE SOPRA E SOTTO $cov(x_i, x_j)$ DISPOSTA SIMMETRICAMENTE A $cov(x_i, x_j)$, CON LO STESSO VALORE.

→ SI PUÒ ANCHE NORMALIZZARE PER $\sigma_i\sigma_j$ E OTTENERE LA MATRICE DEI COEFF. DI CORR. LINEARE

$$\begin{pmatrix} \sigma_{11} & cov(x_1,x_2) & \cdots \\ cov(x_2,x_1) & \ddots & \vdots \\ \vdots & \cdots & \sigma_{nn} \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & \rho_{12} & \cdots \\ \rho_{21} & \ddots & \vdots \\ \vdots & \cdots & 1 \end{pmatrix}$$

($\binom{n}{2}$ → n VALORI DA ACCOPPIARE 2 A 2)

PERTANTO OTTENIAMO CHE LA POSTERIOR È GAUSSIANA → $x-\sigma<\mu<x+\sigma$ AL 68,3%.

$$f(\mu|x) \propto f(x|\mu)$$

$x-2\sigma<\mu<x+2\sigma$ AL 95,2%.

L'OBIETTIVO È LIMITARE LA DIPENDENZA DALLA PRIOR (AUMENTO MISURE). PER n MISURE (INDIPENDENTI) SI OTTIENE:

$$\mathcal{L}(\vec{x}|\mu) = \prod_i^n \mathcal{L}(x_i|\mu) = \prod_i^n \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{(x_i-\mu)}{\sigma_i}\right]^2} = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n e^{-\frac{1}{2}\sum_i^n\left[\frac{x_i-\mu}{\sigma_i}\right]^2}$$

→ MASSIMIZZIAMO LA LIKELIHOOD PER MINIMIZZARE LA DIPENDENZA DA f_0:

POICHÉ IL $\log$ È UNA FUNZIONE MONOTONA CRESCENTE ALLORA IL PUNTO DI MASSIMO DI $\mathcal{L}$ E $\log\mathcal{L}$ È IL MEDESIMO: $\log(\mathcal{L}) = \sum_i \log(\mathcal{L}(x_i|\mu)) = \sum_i \log\left[\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma}\right]^2}\right] =$

$$= \sum_i^n \left[\log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(x-\mu)^2}{2\sigma^2}\right] = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_i^n (x_i-\mu)^2$$

→ CERCO IL MASSIMO QUINDI DERIVO E PONGO UGUALE A 0:

$$\frac{\partial}{\partial\mu}\left[-\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_i^n (x_i-\mu)^2\right] = +\frac{1}{\sigma^2}\sum_i^n (x_i-\mu) = 0 \Rightarrow \sum_i^n (x_i-\mu) = 0 \Rightarrow \hat{\mu} = \frac{1}{n}\sum_i^n x_i = \bar{x}$$

→ POSSO ORA CONSIDERARE LA DERIVATA SECONDA, PER SVILUPPARE CON TAYLOR AL 2° ORDINE VICINO AL MASSIMO.

$$\frac{\partial}{\partial^2\mu}\log^0(\mathcal{L}(\mu|x))^2 = -\frac{n}{\sigma^2} \Rightarrow \sigma_\mu^2 = \frac{n}{\frac{\partial^2}{\partial\mu^2}[\log\mathcal{L}]}$$

(n MISURE RIPETUTE)

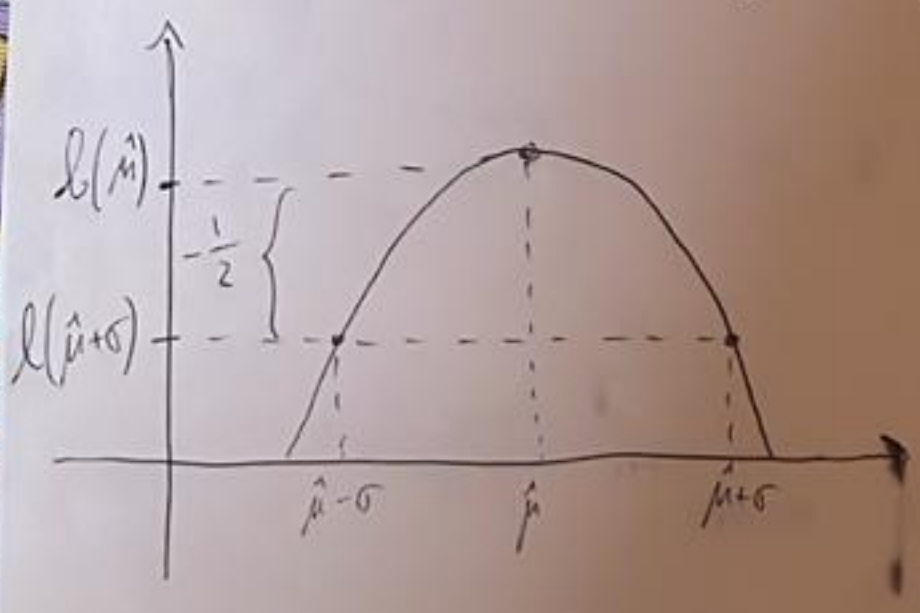
$$\log\mathcal{L} = \log(\mathcal{L})\Big|_{\hat{\mu}} + \underbrace{(\mu-\hat{\mu})\left(\frac{\partial\mathcal{L}}{\partial\mu}\Big|_{\hat{\mu}}\right)}_{0\ (\text{DER. 1ª NEL P. CRITICO NULLA})} - \frac{1}{2}\frac{n}{\sigma^2}(\mu-\hat{\mu})^2 + o\left[(x-\mu)^3\right]$$

$$\log\mathcal{L} = \log(\mathcal{L})\Big|_{\hat{\mu}} - \frac{1}{2}\frac{n}{\sigma^2}\sigma^2 \quad (\text{DOVE } (\mu-\hat{\mu})=\sigma) \quad (*)$$

→ VEDIAMO CHE SUCCEDE A 1σ DI DISTANZA

$$\Rightarrow \log(\mathcal{L}) - \log(\mathcal{L})\Big|_{\hat{\mu}} = -\frac{1}{2}n$$

ORA SE $n=1$, DEFINENDO $\log\mathcal{L} = l(\mu)$: $l(\mu) - l(\hat{\mu}) = -\frac{1}{2} \rightarrow \Delta l = -\frac{1}{2}$



- SE TI TROVI NEL MASSIMO E TI SPOSTI A DESTRA/SINISTRA DI σ LA $\log\mathcal{L}$ SCENDE SEMPRE DI UN VALORE DI 0,5
- SE n CRESCE LA CURVA SI STRINGE E QUINDI Δl CRESCE IN MODULO

(*) $\Delta l = -\frac{1}{2}\frac{n}{\sigma^2}(\Delta\mu)^2 \rightarrow \frac{\sigma^2}{n} = \Delta\mu^2 \rightarrow \Delta\mu = \frac{\sigma}{\sqrt{n}}$ (TORNA TUTTO)

Δl (=) $-\frac{1}{2}$

MISURE DI EVENTI RIPETUTI CON COMBINAZIONE DI PIÙ SIGMA

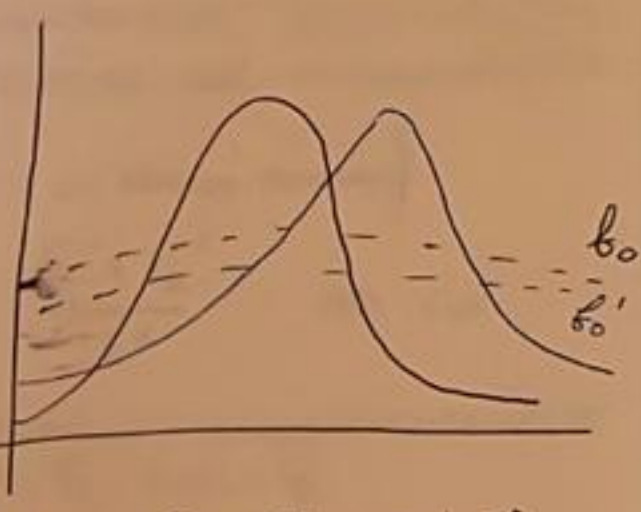
DEF: DEFINIAMO LE INCERTEZZE DI <u>TIPO A</u> SECONDO GLI STANDARD ISO COME LE INCERTEZZE STIMATE DA MISURE RIPETUTE (IN COND. DI RIPETIBILITÀ), RIDUCIBILI AUMENTANDO IL NUMERO DELLE MISURE STESSE. PER INCERTEZZE DI TIPO B SI INTENDONO TUTTE LE ALTRE.

COMBINIAMO PIÙ MISURE FACENDO INFERENZA DI COMBINAZIONE.

T° BAYES: $f(\mu|x,\sigma_e;x',\sigma') = \dfrac{\mathcal{L}(x,\sigma_e|\mu)\,\mathcal{L}'(\mu|x'\sigma')}{\int_{-\infty}^{+\infty}\mathcal{L}(x,\sigma_e|\mu)\,\mathcal{L}'(\mu|x'\sigma')\,d\mu} =$

PRIOR VAGA / COSTANTE GIÀ SEMPLIFICATA

↑ LIKELIHOODS GAUSSIANE



$$= \frac{\frac{1}{\sigma_e\sqrt{2\pi}}e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma_e}\right]^2}\cdot\frac{1}{\sigma'\sqrt{2\pi}}e^{-\frac{1}{2}\left[\frac{x'-\mu}{\sigma'}\right]^2}}{\int_{-\infty}^{+\infty}\frac{1}{\sigma_e\sqrt{2\pi}}e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma_e}\right]^2}\cdot\frac{1}{\sigma'\sqrt{2\pi}}e^{-\frac{1}{2}\left[\frac{x'-\mu}{\sigma'}\right]^2}d\mu} = \frac{e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma_e}\right]^2-\frac{1}{2}\left[\frac{x'-\mu}{\sigma'}\right]^2}}{\int_{-\infty}^{+\infty}e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma_e}\right]^2-\frac{1}{2}\left[\frac{x'-\mu}{\sigma'}\right]^2}d\mu}\ \star$$

$$\exp\left(-\frac{1}{2}\left(\frac{(x-\mu)^2}{\sigma_e^2}+\frac{(x'-\mu)^2}{\sigma'^2}\right)\right) = \exp\left(-\frac{1}{2}\left(\frac{x^2+\mu^2-2x\mu}{\sigma_e^2}-\frac{x'^2+\mu^2-2x'\mu}{\sigma'^2}\right)\right) = \exp\left(-\frac{1}{2}\left(\frac{x^2\sigma'^2+\mu^2\sigma'^2-2x\mu\sigma'^2+x^2\sigma_e^2+\mu^2\sigma_e^2-2x'\mu\sigma_e^2}{\sigma'^2\sigma_e^2}\right)\right)$$

(NON DIPENDONO DA μ QUINDI SI SEMPLIFICANO CON L'INTEGRALE SOTTO DI LUI)

$$= \exp\left(-\frac{1}{2}\left(\frac{\mu^2(\sigma'^2+\sigma_e^2)}{\sigma'^2\cdot\sigma_e^2}-\frac{2\mu(x\sigma'^2+x'\sigma_e^2)}{\sigma'^2\cdot\sigma_e^2}\right)\right) = \exp\left(-\frac{1}{2}\left(\frac{\mu^2}{\frac{\sigma'^2\cdot\sigma_e^2}{\sigma'^2+\sigma_e^2}}-2\mu\left[\frac{x}{\sigma_e^2}+\frac{x'}{\sigma'^2}\right]\right)\right) =$$

$$= \exp\left(-\frac{1}{2}\left(\frac{\mu^2-\frac{2\mu\left(\frac{x}{\sigma_e^2}+\frac{x'}{\sigma'^2}\right)}{\left(\frac{\sigma'^2+\sigma_e^2}{\sigma'^2\sigma_e^2}\right)}}{\left(\frac{\sigma'^2\cdot\sigma_e^2}{\sigma'^2+\sigma_e^2}\right)}\right)\right) \Rightarrow \text{DEFINIAMO} \begin{cases}\frac{1}{\sigma_A^2} = \frac{1}{\sigma_e^2}+\frac{1}{\sigma'^2}\\ \mu_A = \frac{\frac{x}{\sigma_e^2}+\frac{x'}{\sigma'^2}}{\frac{1}{\sigma_e^2}+\frac{1}{\sigma'^2}}\end{cases}$$

$$= \exp\left(-\frac{1}{2}\left(\frac{\mu^2-2\mu\mu_A}{\sigma_A^2}\right)\right) \Rightarrow \star = \frac{e^{-\frac{1}{2}\left(\frac{\mu^2-2\mu\mu_A}{\sigma_A^2}\right)}}{\int_{-\infty}^{+\infty}e^{-\frac{1}{2}\left(\frac{\mu^2-2\mu\mu_A}{\sigma_A^2}\right)}d\mu} = \frac{e^{-\frac{1}{2}\left(\frac{\mu-\mu_A}{\sigma_A}\right)^2}}{\int_{-\infty}^{+\infty}e^{-\frac{1}{2}\left(\frac{\mu-\mu_A}{\sigma_A}\right)^2}d\mu} =$$

(COMPLETO IL QUADRATO TANTO $\frac{\mu_A^2}{\sigma_A^2}$ NON DIPENDE DA μ)

→ INTEGRALE NOTEVOLE

$$= \frac{1}{\sigma_A\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{x-\mu_A}{\sigma_A}\right)^2}$$

OSSERVA: σ_A ($\sigma_{RISULTATO}$) È SEMPRE MINORE DELLE SIGMA DA CUI È GENERATA

(ES): SE $\sigma' = \sigma_e = \sigma \Rightarrow \sigma_A = \frac{\sigma}{\sqrt{2}}$

PER CUI RICONFERMIAMO CHE AUMENTANDO LA STATISTICA, POSSIAMO ABBATTERE ALCUNI TIPI DI INCERTEZZE (LE TIPO A, APPUNTO)

TEOREMA DEL LIMITE CENTRALE

- COME SI FA SE NON CONOSCIAMO LA PDF? PRESE n VARIABILI CASUALI X_i, DATE ALCUNE IPOTESI, POSSO RICONDURRE TUTTO AL CASO NOTEVOLE GAUSSIANO GRAZIE AL T.L.C.

IPOTESI: 1) n VARIABILI CASUALI X_i INDIPENDENTI TRA LORO (PDF ANCHE DIVERSE) MISURATE IN COND. DI RIPETIBILITÀ
2) $n \to \infty$ 3) $\alpha_i^2 \sigma_i^2 \ll \sigma^2$ (NESSUNA VARIANZA DOMINANTE)

$\Rightarrow$ LA COMB. LINEARE $Y = \sum_i^n \alpha_i X_i$ TENDERÀ A DISTRIBUIRSI COME UNA GAUSSIANA CIOÈ

$$\lim_{n\to\infty} Y \to N(\mu, \sigma) \quad \text{DOVE} \quad \begin{cases} \mu = \sum_i^n \alpha_i \mu_i \\ \sigma_0 = \sqrt{\sum_i^n \alpha_i^2 \sigma_i^2} \end{cases}$$

CASI PARTICOLARI:

MEDIA: $\bar{y} = \bar{x} = \sum_{i=1}^n \frac{x_i}{n}$

n VARIABILI CASUALI INDIPEND. E ANALOGHE $\to$ $\begin{cases} \sigma_i = \sigma \ \forall i \\ \alpha_i = \frac{1}{n} \ \forall i \\ \mu_i = \mu \ \forall i \end{cases}$

$$\lim_{n\to\infty} \bar{x} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

FUNZ. LINEARIZZATA: $y = y(x_1 \dots x_n) \simeq K + \sum_{i=1}^n \left.\frac{\partial y}{\partial x_i}\right|_{\mu_i} x_i$ QUINDI y È COMB. LINEARE DI x_i CON COEFF. LE DERIVATE PARZIALI. SE VALE QUINDI $\alpha_i^2 \sigma_i^2 \ll \sigma^2$ ALLORA PER IL T.L.C.

$$\lim_{n\to\infty} Y \sim N(\mu_y, \sigma_y) \quad \text{DOVE} \quad \begin{cases} \mu_y = y(\mu_1 \dots \mu_n) \\ \sigma_y = \sqrt{\sum_i \left(\left.\frac{\partial y}{\partial x_i}\right|_{\mu_i} 1\right)^2 \sigma_i^2} \end{cases}$$

ERRORE: $\varepsilon_i = x_i - \mu$ (ERRORE i-ESIMA MISURA)

$E[\varepsilon_i] = 0 \quad \varepsilon_{TOT} = \sum_i \varepsilon_i \quad \sigma_x^2 = \sum_i \sigma_{x,i}^2$ $\to$ SE $\sigma_x^2 \ll \sigma_0^2$ PER IL TLC $\varepsilon_{TOT} \sim N$

DOVE A SEGUITO DI UNA MISURA HO OTTENUTO $\begin{cases} \bar{x}^* = \frac{1}{n}\sum x_i \\ s_{n-1}^2 = \frac{1}{n-1}\sum (x_i - \bar{x}^*)^2 \end{cases}$ $\Rightarrow X = \bar{x}^* \pm \frac{s_{n-1}}{\sqrt{n}}$

INFERENZA BAYESIANA

- PER INFERENZA SI INTENDE QUEL PROCESSO CHE UTILIZZIAMO PER AGGIORNARE IL NOSTRO STATO DI INFORMAZIONE SU UN EVENTO, CIOÈ VOGLIAMO AGGIORNARE LA PROBABILITÀ PER CUI LA MISURA OTTENUTA SIA STATA CAUSATA DALL'IPOTESI CON VALOR VERO μ:

$$\underbrace{f(\mu|x)}_{\text{POSTERIOR}} \propto \underbrace{\mathcal{L}(x|\mu)}_{\text{LIKELIHOOD}} \underbrace{f_0(\mu)}_{\text{PRIOR}}$$

$\to$ PER ORA LIMITIAMOCI AL CASO DI ROUTINE, OVVERO CON $\mathcal{L}$ GAUSSIANA, σ NOTA, PRIOR VAGA ($\overset{\text{MAROX}}{\text{COSTANTE}}$)

$$f(\mu|x) = \frac{\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{(x-\mu)}{\sigma}\right]^2} \cdot \cancel{f_0(\mu)}}{\underbrace{\int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{(x-\mu)}{\sigma}\right]^2}}_{1 \text{ PER LA NORMALIZZAZIONE}} \cdot f_0(\mu)\, d\mu} \quad \begin{matrix} \nearrow \text{COSTANTE QUINDI SI SEMPLIFICA} \\ \end{matrix}$$

$= \mathcal{L}(x|\mu) \Rightarrow f(\mu|x) = \mathcal{L}(x|\mu)$ — INVERSIONE DELLA PROBABILITÀ!

FIT DI DATI SPERIMENTALI

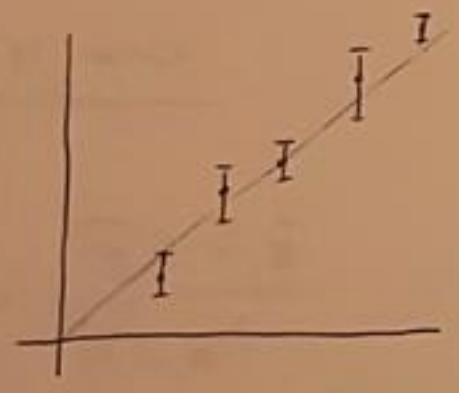
- DATO UN SISTEMA FISICO E UNA SERIE DI MISURE, SI VUOLE CERCARE UNA RELAZIONE CHE LEGHI LE GRANDEZZE E CHE SI SOVRAPPONGA AL MEGLIO AI NOSTRI DATI SPERIM. TALE FUNZIONE È DETTA <u>BEST FIT</u>. PER FARLO SI CONSIDERANO UNA SERIE DI COPPIE $\begin{cases} x_i \pm \sigma_{x_i} \\ y_i \pm \sigma_{y_i} \end{cases}$ t.c. $y = f(x, z_1, \dots, z_n)$ DOVE z_i SONO I PARAMETRI INCOGNITI DEL MODELLO.

- I DATI DEVONO RISPETTARE 3 IPOTESI FONDAMENTALI:

1) MISURE INDIPENDENTI TRA LORO
2) TRASCURIAMO L'INCERTEZZA SU UNA DELLE 2 GRANDEZZE → $x_i \sim \delta$ (DELTA DI DIRAC)
3) GLI ERRORI DI MISURA SULLA VAR. DIPENDENTE (*) SEGUONO → DISTRIBUZIONE GAUSSIANA.

FIT LINEARE

- LA FORMA DEL BEST FIT CHE SI CERCA È UNA RETTA: $y = mx + c$ DOVE m E c SONO I PARAMETRI DEL FIT (z_1 E z_2) CIOÈ I VALORI CHE VOGLIAMO INFERIRE. IN QUESTO TIPO DI FIT L'IPOTESI DI TRASCURARE LE INCERTEZZE SULLE x_i DIVENTA FONDAMENTALE



$$x_i \sim \delta(x_i - \mu_i) = \begin{cases} 1 & \text{SE } x_i = \mu_i \\ 0 & \text{SE } x_i \neq \mu_i \end{cases}$$

- IMPOSTIAMO INTANTO IL 1° DI BAYES PER L'INFERENZA $\mathcal{L} = f(x_i, y_i \mid m, c)$ E UTILIZZIAMO LA LEGGE DI MOLTIPLICAZIONE DELLE PROBABILITÀ PER CUI $\mathcal{L} = \underbrace{f(x_i \mid \mu_{x_i}, \sigma_{x_i})}_{1 \text{ PER } \delta(x_i - \mu_i)} f(y_i \mid \mu_x, m, c)$

ORA SUPPONENDO SIANO GAUSSIANE E CONSIDERANDO UNA SINGOLA COPPIA DI PUNTI:

$$\mathcal{L} = \frac{1}{\sigma_{y_i}\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{y_i - \mu_{x_i}}{\sigma_{y_i}}\right]^2} = \frac{1}{\sigma_i\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{y_i - m\mu_{x_i} - c}{\sigma_i}\right]^2}$$

$\sigma_{y_i} = \sigma_i$

SE CONSIDERIAMO n COPPIE, LA VEROSIMIGLIANZA TOTALE È: $\mathcal{L}_{TOT} = \prod_i^n \mathcal{L}(x_i, y_i \mid m, c)$

$f_{POST}(m, c \mid \vec{x}, \vec{y}) \propto \mathcal{L}_{TOT} \cdot f_0(m, c)$ → SUPPONIAMO PRIOR UNIF (COSTANTE):

$$f_{POST}(m, c \mid \vec{x}, \vec{y}) = \prod_i^n \frac{1}{\sigma_i\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{y_i - mx_i - c}{\sigma_i}\right]^2}$$

APPLICHIAMO ORA IL METODO DELLA MASSIMA VEROSIMIGLIANZA CON LA $\log(\mathcal{L})$

$$\log\mathcal{L} = -n\log(\sqrt{2\pi}) - \sum_i \log(\sigma_i) - \frac{1}{2}\underbrace{\sum_i \left[\frac{y_i - mx_i - c}{\sigma_i}\right]^2}_{\to \chi^2}$$

MASSIMIZZARE LA $\log(\mathcal{L})$ SIGNIFICA TROVARE IL MINIMO PER χ^2 (MAX LIKELIHOOD ↔ LEAST SQUARE)

$$\begin{cases} \frac{\partial \chi^2}{\partial m} = 0 \rightarrow (1) \\ \frac{\partial \chi^2}{\partial c} = 0 \rightarrow (2) \end{cases} \quad (1)\ \frac{\partial \chi^2}{\partial m} = \sum_i 2\left[\frac{y_i - m x_i - c}{\sigma_i^2}\right](-x_i) = 0 \iff$$

$$\iff \sum_i \frac{y_i x_i}{\sigma_i^2} - \frac{m x_i^2}{\sigma_i^2} - \frac{c x_i}{\sigma_i^2} = 0 \iff$$

$$\iff \sum_i \left(\frac{\frac{y_i x_i}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} - \frac{\frac{m x_i^2}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} - \frac{\frac{c x_i}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} \right) = \overline{xy} - m\overline{x^2} - c\overline{x} = 0$$

↓ MEDIE PESATE

$$(2)\ \frac{\partial \chi^2}{\partial c} = \sum_i 2\left[\frac{y_i - m x_i - c}{\sigma_i^2}\right](-1) = 0 \iff \sum_i \frac{y_i}{\sigma_i^2} - \frac{m x_i}{\sigma_i^2} - \frac{c}{\sigma_i^2} = 0$$

$$\iff \sum_i \left(\frac{\frac{y_i}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} - \frac{\frac{m x_i}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} - \frac{\frac{c}{\sigma_i^2}}{\left(\sum_i \frac{1}{\sigma_i^2}\right)} \right) = \overline{y} - m\overline{x} - c = 0$$

↓ MEDIE PESATE

$$\Rightarrow \begin{cases} \overline{xy} - \hat{m}\overline{x^2} - \hat{c}\overline{x} = 0 \\ \overline{y} - \hat{m}\overline{x} - \hat{c} = 0 \end{cases} \Rightarrow \begin{cases} \overline{xy} - \hat{m}\overline{x^2} - \overline{y}\,\overline{x} + \hat{m}\overline{x}^2 = 0 \\ \hat{c} = \overline{y} - \hat{m}\overline{x} \end{cases} \Rightarrow \begin{cases} \hat{m} = \dfrac{\overline{xy} - \overline{x}\,\overline{y}}{\overline{x^2} - \overline{x}^2} \\ \hat{c} = \dfrac{\overline{x^2}\,\overline{y} - \overline{x}\cdot\overline{xy}}{\overline{x^2} - \overline{x}^2} \end{cases}$$

IN MODO PIÙ COMPATTO $\hat{m} = \dfrac{\mathrm{cov}(x,y)}{\mathrm{var}(x)}$ $\mathrm{var}(x)$ è Γ INDICA COSÌ IL BRACCIO DI LEVA OSSIA QUANTO I VALORI SONO DISPERSI RISPETTO AL BARICENTRO PESATO.

I VALORI $\hat{m}$ E $\hat{c}$, CHE MASSIMIZZANO LA LIKELIHOOD SONO CARATTERIZZATI DA UN'INCERTEZZA:

$$\mathrm{VAR}[\hat{m}] = \sum_i \left(\frac{\partial \hat{m}}{\partial y_i}\right)^2 \sigma_i^2 \qquad \mathrm{VAR}[\hat{c}] = \sum_i \left(\frac{\partial \hat{c}}{\partial y_i}\right)^2 \sigma_i^2 \qquad \mathrm{COV}(\hat{m},\hat{c}) = \sum_i \left(\frac{\partial \hat{m}}{\partial y_i}\right)\left(\frac{\partial \hat{c}}{\partial y_i}\right)\sigma_i^2$$

$$\cdot\ \mathrm{VAR}(\hat{m}) = \sum_i \left[\left[\frac{\partial}{\partial y_i}\left(\frac{\sum_i \frac{x_i y_i}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}} - \frac{\sum_i \frac{x_i}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}} \cdot \frac{\sum_i \frac{y_i}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}} \right)\right]^2\right] \sigma_i^2 =$$

$$= \sum_i \frac{1}{\mathrm{var}^2(x)} \left(\frac{\frac{x_i}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}} - \frac{\frac{\overline{x}}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}} \right)^2 \sigma_i^2 = \sum_i \frac{1}{\mathrm{var}^2(x)} \frac{1}{\sum_i \frac{1}{\sigma_i^2}} \cdot \frac{1}{\sigma_i^2} \left(\frac{x_i - \overline{x}}{\sum_i \frac{1}{\sigma_i^2}} \right)^2 =$$

$$\frac{1}{\mathrm{var}^2(x)\sum_i \frac{1}{\sigma_i^2}} \sum_i \left(\frac{x_i^2 + \overline{x}^2 - 2x_i\overline{x}}{\sigma_i^2 \sum_i \frac{1}{\sigma_i^2}} \right) = \frac{1}{\mathrm{var}^2(x)\sum_i \frac{1}{\sigma_i^2}} \left(\overline{x^2} + \overline{x}^2 - 2\overline{x}^2\right) =$$

$$= \frac{1}{\mathrm{var}^2(x)\sum_i \frac{1}{\sigma_i^2}} \underbrace{\left(\overline{x^2} - \overline{x}^2\right)}_{\mathrm{var}(x)} \Rightarrow \mathrm{VAR}(\hat{m}) = \frac{1}{\mathrm{var}(x)\sum_i \frac{1}{\sigma_i^2}}$$

$$\cdot\ \mathrm{VAR}(\hat{c}) = (\text{SI RICAVA ANALOGAMENTE}) = \frac{\overline{x^2}}{\mathrm{var}(x)\sum_i \frac{1}{\sigma_i^2}}$$

MISURE DI K EVENTI PER N VOLTE (SPAGHETTI)

- IN CHE MODO POSSO RIDURRE σ_B ? MISURO K EVENTI PER N VOLTE. UN ESEMPIO PUÒ ESSERE MISURARE K PERIODI (E NON UNO SOLO) DI UN PENDOLO CON IL CRONOMETRO, ABBATTENDO L'INC. SUL TEMPO DI REAZIONE UMANO PER AVVIARE E FERMARE IL CRONOMETRO. ALTRO ESEMPIO È MISURARE K FOGLI DI CARTA CON UN NONIO PER CAPIRE LO SPESSORE DEL SINGOLO FOGLIO.

IN GENERALE: $X = kx$ (ESEMPIO: X = TEMPO TOT. 5 OSCILL. k = 5 OSCILL. x = PERIODO PENDOLO)

$$\sigma^2[X] = k^2\sigma^2[x] \Rightarrow \sigma^2[x] = \frac{\sigma^2[X]}{k^2} \longrightarrow \sigma^2[x] = \frac{\sigma_A^2 + \sigma_B^2}{k^2} \quad \text{PER CUI}$$

$$\sigma[x] = \frac{1}{k}\sqrt{\frac{s_{n-1}^2}{n} + \sigma_B^2} = \sqrt{\frac{s_{n-1}^2}{nk^2} + \frac{\sigma_B^2}{k^2}} \Rightarrow \text{RIDUCIAMO CONTEMPORANEAMENTE SIA } \sigma_A \text{ SIA } \sigma_B$$

ERRORI SISTEMATICI

- IN GENERALE GLI ERRORI SISTEMATICI SONO QUELLE INCERTEZZE CHE COLPISCONO LA MISURA SEMPRE NELLA STESSA DIREZIONE. LA CARATTERISTICA PRINCIPALE È CHE NON SI RIDUCONO ALL'AUMENTARE DELLE MISURE. ESSI RIENTRANO TIPICAMENTE NELLE INCERTEZZE DI TIPO B. È OPPORTUNO ANALIZZARE, TRA QUESTI, L'ERRORE DI OFFSET E DI SCALA.

OFFSET

$$\begin{cases} \mu_1 = x_1 - \hat{z} \\ \mu_2 = x_2 - \hat{z} \end{cases} \quad \text{PARAMETRI: } \begin{matrix} x_1 & x_2 & z \\ \sigma_1 & \sigma_2 & \sigma_z \end{matrix} \quad \text{LOTIAMO COME } \rho(\mu_1,\mu_2) = \frac{\mathrm{cov}(\mu_1,\mu_2)}{\sigma_1\sigma_2} \neq 0$$

$$\mathrm{cov}(\mu_1,\mu_2) = \sum_{i,j}^{1,n} \frac{\partial\mu_1}{\partial x_i}\frac{\partial\mu_2}{\partial x_j}\sigma_{ij}^2 \quad \text{MA } \forall i \neq s \;\; \sigma_{ij} = 0 \quad \text{CIOÈ} \begin{cases} \mathrm{cov}(x_1,x_2) = 0 \\ \mathrm{cov}(x_i,z) = 0 \end{cases}$$

$$= \underbrace{\frac{\partial\mu_1}{\partial x_1}}_{0}\underbrace{\frac{\partial\mu_2}{\partial x_1}}_{0}\sigma_1^2 + \underbrace{\frac{\partial\mu_1}{\partial x_2}}_{0}\frac{\partial\mu_2}{\partial x_2}\sigma_2^2 + \underbrace{\frac{\partial\mu_1}{\partial z}}_{-1}\underbrace{\frac{\partial\mu_2}{\partial z}}_{-1}\sigma_z^2 \Rightarrow \mathrm{cov}(\mu_1,\mu_2) = \sigma_z^2$$

$$\text{PER CUI } \rho(\mu_1,\mu_2) = \frac{\sigma_z^2}{\sqrt{\sigma_1^2+\sigma_z^2}\sqrt{\sigma_2^2+\sigma_z^2}} \Rightarrow \begin{matrix} \sigma_z \ll \sigma_{1,2} : \rho \to 0 \\ \sigma_z \gg \sigma_{1,2} : \rho \to 1 \end{matrix}$$

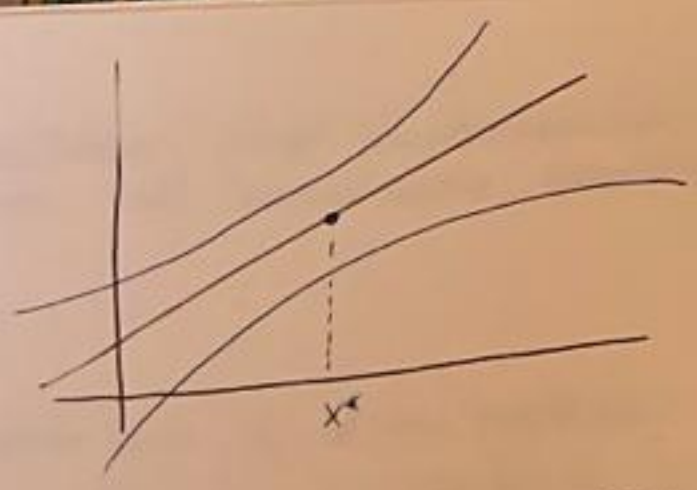
SCALA

$$\begin{cases} \mu_1 = f x_1 \\ \mu_2 = f x_2 \end{cases} \quad \text{PARAMETRI: } \begin{matrix} x_1 & x_2 & f \\ \sigma_1 & \sigma_2 & \sigma_f \end{matrix} \quad \mathrm{cov}(\mu_1,\mu_2) = \frac{\partial\mu_1}{\partial f}\frac{\partial\mu_2}{\partial f}\sigma_f^2 = x_1x_2\sigma_f^2$$

$$\sigma^2(\mu_i) = \left(\frac{\partial\mu_i}{\partial x_i}\right)^2\sigma_i^2 + \left(\frac{\partial\mu_i}{\partial f}\right)\sigma_f^2 = f^2\sigma_i^2 + x_i^2\sigma_f^2 \Rightarrow \rho(\mu_1,\mu_2) = \frac{x_1x_2\sigma_f^2}{\sqrt{f^2\sigma_1^2+x_1^2\sigma_f^2}\sqrt{f^2\sigma_2^2+x_2^2\sigma_f^2}}$$

NOTA: POTREBBERO ANCHE ESSERE PRESENTI CONTEMPORANEAMENTE, QUESTI DUE TIPI DI ERRORE SI GESTISCONO CON UN'OPPORTUNA RETTA DI CALIBRAZIONE ($y = fx + z$)

BANDE DI INCERTEZZA (CURVE DI INVILUPPO)



- LE BANDE D'INCERTEZZA FORMANO UNA SORTA DI IPERBOLE ATTORNO AL FIT. MAN MANO CHE CI SI ALLONTANA DAL CENTRO DEI DATI (PUNTO DI STROZZATURA)
- ANCHE NEL BARICENTRO L'INCERTEZZA NON È NULLA A CAUSA DEL FATTORE $\sqrt{\overline{x^2}}$ (METODO ROOT MEAN SQUARE)
- LE NOSTRE BANDE DI INCERTEZZA INDICANO QUINDI QUANTO IL MODELLO SIA AFFIDABILE IN UN CERTO PUNTO E CI DICONO ANCHE A FARE EVENTUALI PREVISIONI DAL FIT.

$\mu_y = \hat{m}\mu_x + \hat{c}$ (DOVE μ_x È UN PARAMETRO CHE SCELGO PER TESTARE IL FIT)

$$\text{VAR}[\mu_y] = \sum_{i,j}^{1,n} \left(\frac{\partial \mu_y}{\partial x_i}\right)\left(\frac{\partial \mu_y}{\partial x_j}\right)\Big|_{\mu_1 \dots \mu_n} \sigma_{ij} = \left(\frac{\partial \mu_y}{\partial \hat{m}}\right)^2 \sigma^2(\hat{m}) + \left(\frac{\partial \mu_y}{\partial \hat{c}}\right)^2 \sigma^2(\hat{c}) + 2\left(\frac{\partial \mu_y}{\partial \hat{m}}\right)\left(\frac{\partial \mu_y}{\partial \hat{c}}\right) \text{cov}(\hat{m}, \hat{c}) =$$

$\sigma_i = \sigma_x$

$$= \mu_x^2 \frac{\sigma^2}{\text{VAR}(x)\,n} + \frac{\overline{x^2}\,\sigma^2}{\text{VAR}(x)\,n} - 2\mu_x \frac{\sigma^2 \overline{x}}{\text{VAR}(x)\,n} = \frac{\sigma^2}{n\,\text{VAR}(x)}\left(\mu_x^2 + \overline{x^2} - 2\mu_x \overline{x}\right) =$$

$$= \frac{\sigma^2}{n\,\text{VAR}(x)}\left(\mu_x^2 + \overline{x}^2 - \overline{x}^2 + \overline{x^2} - 2\mu_x \overline{x}\right) = \frac{\sigma^2}{n} + \frac{\sigma^2}{n\,\text{VAR}(x)}\left(\mu_x - \overline{x}\right)^2$$

$\text{VAR}(x)$

$$\Rightarrow \sigma(\mu_y) = \frac{\sigma}{\sqrt{n}}\sqrt{1 + \frac{(\mu_y - \overline{x})^2}{\text{VAR}(x)}} \quad \text{(CASO } \sigma_i \text{ COSTANTI E UGUALI)}$$

$$\Rightarrow \text{(SE } \sigma_i \text{ SONO DIVERSE)} \quad \sigma(\mu_y) = \sqrt{\frac{1}{P} + \frac{(\mu_x - \overline{x})^2}{\text{VAR}(x)\,P}} \quad \text{DOVE } P = \sum_i \frac{1}{\sigma_i^2}$$

- LE CURVE/BANDE D'INCERTEZZA SONO DATE DA $y = \hat{m}x + \hat{c} \pm k\sigma(\mu_y)$ (POI SI PUÒ SCEGLIERE IL VALORE DI K)

DISTRIBUZIONI DISCRETE

- LE DISTR. ANALIZZATE FINO AD ORA SONO CONTINUE. RISULTANO PERÒ FONDAMENTALI ANCHE QUELLE DI TIPO DISCRETO, OVVERO QUELLE DISTR. CHE DESCRIVONO FENOMENI I CUI POSSIBILI RISULTATI SONO NUMERABILI O ISOLATI

PROCESSO DI BERNOULLI

- ABBIAMO UNA CLASSE [redacted] DI EVENTI [redacted] CARATTERIZZATI DA 2 ESITI POSSIBILI: HIT (E) O MISS $(\bar{E})$ IN MODO CHE $\bar{E} \cup E = \Omega$ PER CUI AVREMO UN ESITO BINARIO

$$X \sim f(x) \qquad x = 0,1 \; : \; f(x=1) = p \qquad f(x=0) = q = (1-p)$$

- ASSUMENDO INDIPENDENZA TRA UNA PROVA E L'ALTRA, E STAZIONARIETÀ (p E q RIMANGONO COSTANTI) POSSIAMO STUDIARE LA PROBABILITÀ DI AVERE k SUCCESSI.

$$P(k=n \mid B_{n,p}) = P(\bar{E}_1 \cap \dots \cap \bar{E}_n) \bullet = P(\bar{E}_1) \dots P(\bar{E}_n) = p^n$$

$$\Rightarrow P(k \mid B_{n,p}) = p^k (1-p)^{n-k}$$ (QUI SUPPONIAMO CHE k SUCCESSI AVVENGANO IN UNA SEQ. PRESTABILITA, AD ESEMPIO NEI PRIMI k LANCI)

- SE NON MI INTERESSA L'ORDINE INTRODUCO IL COEFFICIENTE BINOMIALE $\binom{n}{k} = \frac{n!}{k!(n-k)!}$

$$\Rightarrow P(k \mid B_{n,p}) = \binom{n}{k} p^k (1-p)^{n-k}$$ → BINOMIALE (GENERATA DA UNA COMB. DI PROCESSI DI BERNOULLI)

- VALORE ATTESO E VARIANZA BERNOULLI:

$$\mu = E[x \mid B_p] = \sum_i x_i f(x_i) = 0(1-p) + [redacted] \, 1\,(p) = p$$

$$\mathrm{VAR}[x \mid B_p] = E[(x-\mu)^2] = E[x^2] - E[x]^2 = p - p^2 = p(1-p) = pq \rightarrow \text{SE } p = \tfrac{1}{2} \text{ È MAX}$$

- VALORE ATTESO E VARIANZA BINOMIALE (k SUCCESSI SU n PROVE):

$$B(k,n,p) = \binom{n}{k} p^k (1-p)^{n-k} \Rightarrow \sum_{k=0}^{n} B(k,n,p) = (p+(1-p))^n = 1^n = 1 \rightarrow \text{ok NORMALIZZAZ.}$$

↓ BINOMIO DI NEWTON

$$E[x \mid B_{n,p}] = \sum_{x=0}^{n} x\, f(x \mid B) = \sum_{x=0}^{n} x \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} = np \sum_{x=1}^{n} \frac{(n-1)!}{(x-1)!(n-x)!} p^{x-1} (1-p)^{n-x} =$$

$$= np \underbrace{\sum_{x=0}^{n} \binom{n-1}{x-1} p^x (1-p)^{n-x}}_{1} = np$$

$$\mathrm{VAR}[x \mid B_{n,p}] = E[x^2] - E[x]^2 \bullet \quad E[x^2] = \sum_{x=0}^{n} x^2 \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} = \overset{x^2 = x(x-1)+x}{\rightarrow}$$

$$= \sum_x x \frac{n!}{(n-x)!x!} p^x (1-p)^{n-x} + \sum_x x(x-1) \frac{n!}{(n-x)!x!} p^x (1-p)^{n-x} = np + \sum_x \frac{n!}{(x-2)!(n-x)!} p^x (1-p)^{n-x} =$$

$$np + n(n-1)p^2 \sum_x \frac{(n-2)!}{(x-2)!(n-x)!} p^{x-2} (1-p)^{n-x} = np + n(n-1)p^2$$

$$\mathrm{VAR}[x \mid B_{n,p}] = np + n(n-1)p^2 - n^2p^2 = np + \cancel{n^2p^2} - np^2 - \cancel{n^2p^2} = np(1-p) = npq$$

DISTRIBUZIONE GEOMETRICA

- PROBABILITÀ DI AVERE SUCCESSO PER LA PRIMA VOLTA ALLA PROVA x (PROC. DI BERNOULLI)

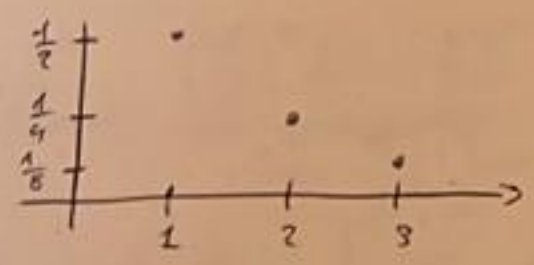
$$f(x) = p(1-p)^{x-1} = (\text{SUCCESSO 1 VOLTA})(\text{INSUCCESSO } x-1 \text{ VOLTE})$$

- NORMALIZZAZIONE: $\sum_{1}^{+\infty} f(x_i) = \sum_{1}^{+\infty} p(1-p)^{x_i-1} = p \sum_{1}^{\infty} q^{x-1} = p \frac{1}{1-q} = 1$ (converge siccome $-1<q<1$)

$f(1) = p$ $\quad p=\frac{1}{2} \rightarrow \quad f(1) = \frac{1}{2}$

$f(2) = p(1-p)$ $\quad \rightarrow \quad f(2) = \frac{1}{4}$

$f(3) = p(1-p)^2$ $\quad \rightarrow \quad f(3) = \frac{1}{8}$



- PROPRIETÀ ASSENZA DI MEMORIA: $P(X > n+m \mid X > n) = P(X > m)$

SE IL 1° SUCCESSO NON È AVVENUTO ENTRO n VOLTE, LA PROB. CHE IL 1° SUCCESSO SIA DOPO $m+n$ TENTATIVI, NON DIPENDE DA n.

- VALORE ATTESO E VARIANZA DISTR. GEOMETRICA:

$$\mu[x] = \sum_{x=1}^{N} x f(x) = \sum_{x=1}^{N} x (1-p)^{x-1} p = p \sum_{x=1}^{N} x q^{x-1} = p \frac{d}{dq} \sum_{x=1}^{N} q^x = p \frac{d}{dq}\left(\frac{1}{1-q}\right) =$$

$$= \frac{p}{(1-q)^2} = \frac{p}{p^2} = \frac{1}{p}$$

$\text{VAR}[x] = \frac{q}{p^2}$ QUINDI SE (ESEMPIO) $p = q = \frac{1}{2}$ $\quad \text{VAR}(x) = \frac{\frac{1}{p}}{p} = E[x] = 2$

BINOMIALE

- VALORE ATTESO, NORMALIZ. E VARIANZA CALCOLATI GIÀ $\rightarrow$ $B(k,n,p) = \binom{n}{k} p^k (1-p)^{n-k}$

- LA BINOMIALE SI PUÒ UTILIZZARE PER MISURARE L'EFFICIENZA.

X = SUCCESSI n = PROVE $\quad \epsilon = \frac{x}{n} \quad P\left(\epsilon = \frac{x}{n}\right) = P(X = x)$

$$f(\epsilon) = \binom{n}{n\epsilon} p^{n\epsilon} (1-p)^{n(1-\epsilon)} \quad \text{con} \quad \begin{cases} n \in \mathbb{N} \\ 0 \le p \le 1 \\ 0 \le \epsilon \le 1 \end{cases}$$

$$E[\epsilon] = E\left[\frac{x}{n}\right] = \frac{1}{n} E[x] = \frac{np}{n} = p \qquad \sigma[\epsilon] = \sigma\left[\frac{x}{n}\right] = \frac{1}{n}\sigma[x] = \frac{\sqrt{npq}}{n} = \sqrt{\frac{pq}{n}}$$

- TENDENZA GAUSSIANA: PER $n \to \infty$ (TLC) E p COSTANTE: $B_{n,p}(x) \to N(np; \sqrt{npq})$

- DEFINIAMO UNA NUOVA V.C. OVVERO LA FREQUENZA RELATIVA DI SUCCESSO:

$f_n := \frac{x}{n}$ CON $0 \le f_n \le 1$ E $x \sim B_{n,p}$ (VAL. ATTESO E σ CALCOLATI SOPRA CON L'EFFICIENZA)

- ESEMPIO UTILIZZO: RANDOM-WALK UNIDIMENSIONALE

$S = X - Y$ = (SPOSTAMENTI IN AVANTI) − (SPOSTAMENTI INDIETRO) $\quad n$ = NUMERO TOT. LANCI MONETA (SPOSTAMENTI)

$$\begin{cases} n = x + y \\ S = x - y \end{cases} \Rightarrow S = 2X - n \qquad E[S] = 2(np) - n = 2 \cdot \frac{1}{2} n - n = 0$$

$$\text{VAR}[S] = \text{VAR}[2x - n] = 4\,\text{VAR}[x] = 4npq = 4n\frac{1}{2}\frac{1}{2} = n \Rightarrow \sigma[S] = \sqrt{n}$$

$$f_n(s) = P\left(x = \frac{s+n}{2}\right) = \binom{n}{\frac{s+n}{2}} p^{\frac{n+s}{2}} (1-p)^{n-\left(\frac{n+s}{2}\right)} = \binom{n}{\frac{n+s}{2}} \cdot \left(\frac{1}{2}\right)^n$$

④ · $\mathrm{cov}(\hat{m},\hat{c}) = \sum_i \left(\frac{\partial \hat{m}}{\partial y_i}\right)\left(\frac{\partial \hat{c}}{\partial y_i}\right)\sigma_i^2 = \sum_i \left(\frac{\frac{x_i}{\sigma_i^2} - \frac{\bar{x}}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}}\right)\left(\frac{\frac{\bar{x}^2}{\sigma_i^2} - \bar{x}\frac{x_i}{\sigma_i^2}}{\sum_i \frac{1}{\sigma_i^2}}\right)\frac{\sigma_i^2}{\mathrm{var}^2(x)} =$

$= \frac{\sum \sigma_i^2}{\mathrm{var}^2(x)} \left(\frac{\sum_i \left\{ \frac{x_i \bar{x}^2}{\sigma_i^2} - \sum_i \frac{x_i^2 \bar{x}}{\sigma_i^2} - \sum_i \frac{\bar{x}\bar{x}^2}{\sigma_i^2} + \sum_i \frac{\bar{x}^2 x_i}{\sigma_i^2} \right)}{\left(\sum_i \frac{1}{\sigma_i^2}\right)^2} \right) \frac{1}{\sum \sigma_i^2} = \frac{\bar{x}^2\bar{x} - \bar{x}^2\bar{x} - \bar{x}\bar{x}^2 + \bar{x}^2\bar{x}}{\mathrm{var}^2(x) \sum_i \left\{ \frac{1}{\sigma_i^2} \right.}$

⑤ $\Rightarrow \mathrm{cov}(\hat{m},\hat{c}) = \frac{-\bar{x}}{\mathrm{var}(x)\sum_i \frac{1}{\sigma_i^2}}$ — { TORNA CHE SIA NEGATIVA (SE m AUMENTA, c DIMINUISCE SICURAMENTE E VICEVERSA)

SE σ_i È NOTA E COSTANTE (LE MEDIE PESATE DIVENTANO ARITMETICHE):

$\sigma^2(\hat{m}) = \frac{\sigma_i^2}{\mathrm{var}(x)\, n} \qquad \sigma^2(\hat{c}) = \frac{\sigma_i^2\, \bar{x}^2}{\mathrm{var}(x)\, n} \qquad \mathrm{cov}(\hat{m},\hat{c}) = \frac{-\bar{x}\,\sigma_i^2}{\mathrm{var}(x)\, n}$

$\Rightarrow \rho(\hat{m},\hat{c}) = \frac{\mathrm{cov}(\hat{m},\hat{c})}{\sigma(\hat{m})\,\sigma(\hat{c})} = \frac{-\bar{x}}{\mathrm{var}(x)\sum \frac{1}{\sigma_i^2}} \frac{\left(\sqrt{\mathrm{var}(x)\sum \frac{1}{\sigma_i^2}}\right)^2}{\sqrt{\bar{x}^2}} = \frac{-\bar{x}}{\sqrt{\bar{x}^2}}$!

RESIDUI

- STUDIAMO L'ANDAMENTO DEI DATI SPERIMENTALI RISPETTO AL MODELLO. CHIAMIAMO LO SCARTO TRA I DATI E LA PREVISIONE <u>RESIDUO</u> $\ell_i = y_i - (\hat{m}x_i + \hat{c})$
- DALL'ANALISI DEI RESIDUI SI POSSONO OTTENERE LE INCERTEZZE A POSTERIORI, PER CAPIRE SE HO SOTTO/SOVRA-STIMATO LE INCERTEZZE INIZIALI.

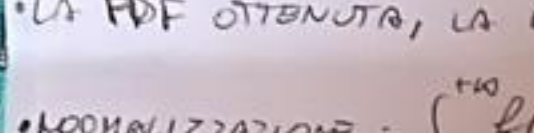
⟶ IN PARTICOLARE COSTRUISCO UNA MEDIA DEGLI SCARTI AL QUADRATO, RICORDANDO n GRADI DI LIBERTÀ (DUMI SPERIMENTALI) MENO 2 VINCOLI $(\hat{m},\hat{c})$:

$\sigma_{RES} = \sqrt{\frac{\sum_i \ell_i^2}{n-2}} = \sqrt{\frac{\sum_i (y_i - \hat{m}x_i - \hat{c})^2}{n-2}}$ NOTA: { SI PUÒ FARE SE $\sigma_i = \sigma\ \forall i$

⟶ SUCCESSIVAMENTE POSSO RISTIMARE $\sigma(\hat{m})$ E $\sigma(\hat{c})$ CON LE FORMULE DEI MINIMI QUADRATI

POISSON NEL TEMPO (TEMPI ATTESA 1° CONT.)

- PASSIAMO DAL CASO DISCRETO DI POISSON AL CONTINUO → IN PARTICOLARE CI INTERESSA LA DISTRIBUZIONE DEI TEMPI DI ATTESA DEI CONTEGGI.
- IPOTESI :
  - INDIPENDENZA DEGLI EVENTI (NON SI INFLUENZANO L'UN. L'ALTRO)
  - STAZIONARIETÀ DELLA FREQUENZA DI CONTEGGIO (RATE = r)
  - NON SIMULTANEITÀ DEGLI EVENTI (UNO ALLA VOLTA)



$\delta t = \frac{T}{N}$ ⇒ PROB SUCCESSO $(\delta t) \propto \delta t$ ∀ INTERVALLO (SUCCESSO = CONTEGGIO)

- FISSIAMO LA RATE (NUM. CONTEGGI PER UNITÀ TEMPO) → $r = \frac{\lambda}{T}$ ⇒ PROB SUCCESSO $(\delta t) = r\,\delta t$

→ SAPENDO QUINDI $p = r\,dt$ POSSIAMO SCRIVERE LA CUMULATIVA, CIOÈ LA PROB. CHE SI VERIFICHI UN EVENTO DOPO UN TEMPO T ⇒ $p(t>T) = \overbrace{(1-p)^n}^{\text{PROB. CHE NON SI VERIFICHI PRIMA DI T}} = (1-r\delta t)^n = \left(1 - r\frac{t}{n}\right)^n$

$$\lim_{n\to+\infty} p(t>T) = \lim_{n\to+\infty}\left(1 - \frac{rt}{n}\right)^n = \underline{e^{-rt}}$$

⇒ $p(0 \le t \le T) = \overbrace{F(t)}^{\text{CUMULAT.}} = 1 - p(t>T) = 1 - e^{-rt}$ (PROB. PRIMO CONTEGGIO TRA $0 \in T$)

⇒ $f(t) = \frac{dF(t)}{dt}$ ⇒ $f(t) = r\,e^{-rt}$

POSSIAMO ORA DEFINIRE LA VITA MEDIA $\tau = \frac{1}{r}$ ⇒ $f(t) = \frac{1}{\tau}e^{-\frac{t}{\tau}}$

- LA PDF OTTENUTA, LA POISSONIANA NEL TEMPO (CONTINUO), È DETTA FUNZIONE ESPONENZIALE

- NORMALIZZAZIONE ; $\int_0^{+\infty} f(t)\,dt = -e^{-rt}\Big|_0^{+\infty} = 1$

- $E[t] = r\int_0^{+\infty} t\,e^{-rt}\,dt = \begin{matrix} D & I \\ +\,t & e^{-rt} \\ -\,1 & \frac{-e^{-rt}}{r} \\ & \frac{e^{-rt}}{r^2} \end{matrix} = r\left(\frac{-te^{-rt}}{r} - \frac{e^{-rt}}{r^2}\right)\Big|_0^{+\infty} = \frac{1}{r} = \tau$

- $E[t^2] = r\int_0^{+\infty} t^2 e^{-rt}\,dt = r\left(\frac{-t^2e^{-rt}}{r} - \frac{2te^{-rt}}{r^2} - \frac{2e^{-rt}}{r^3}\right)\Big|_0^{+\infty} = \frac{2}{r^2}$

- $\mathrm{Var}[t] = \frac{2}{r^2} - \frac{1}{r^2} = \frac{1}{r^2}$ ⇒ $\sigma(t) = \frac{1}{r} = \tau$

→ SCRIVENDO NUOVAMENTE LA POISSONIANA, AVENDO DEFINITO $r = \frac{\lambda}{T}$

$P_\lambda = \frac{\lambda^x}{x!}e^{-\lambda} = \frac{(rt)^x}{x!}e^{-rt}$ CON $\begin{cases} E[x] = rt \\ \mathrm{Var}[x] = rt \Rightarrow \sigma(x) = \sqrt{rt} \end{cases}$

TEMPO ATTESA K-ESIMO EVENTO

$P(E) \equiv$ Prob. K-mo evento si verifichi a un tempo $T > t \equiv$
$\equiv$ Prob. che entro t si siano verificati massimo $K-1$ eventi

$$P(E) = f(0 \mid P_{rt}) + f(1 \mid P_{rt}) + \dots + f(K-1 \mid P_{rt}) = F(K-1 \mid P_{rt})$$

$$P_K(T \le t) = 1 - P(E) = 1 - F(K-1 \mid P_{rt}) = 1 - \sum_{x=0}^{K-1} \frac{e^{-rt}(rt)^x}{x!} = F(t)$$

$$f(t) = \frac{dF(t)}{dt} = \frac{d}{dt}\left(1 - \sum_{x=0}^{K-1} \frac{e^{-rt}(rt)^x}{x!}\right) = -\sum_{x=0}^{K-1} \frac{1}{x!} \frac{d}{dt}\left(e^{-rt}(rt)^x\right)$$

$$\Rightarrow \frac{d}{dt}\left(e^{-rt}(rt)^x\right) = r^x \times t^{x-1} e^{-rt} + (rt)^x e^{-rt}(-r)$$

$$f(t) = -\sum_{x=0}^{K-1} \frac{1}{x!}\left(x r (rt)^{x-1} e^{-rt} - r(rt)^x e^{-rt}\right) = \sum_{x=0}^{K-1} \frac{r(rt)^x e^{-rt}}{x!} - \sum_{x=1}^{K-1} \frac{r(rt)^{x-1} e^{-rt}}{(x-1)!} =$$

$$= \sum_{x=0}^{K-1} \frac{r(rt)^x e^{-rt}}{x!} - \sum_{m=0}^{K-2} \frac{r(rt)^m e^{-rt}}{m!} \overset{?}{=} \frac{r(rt)^{k-1} e^{-rt}}{(k-1)!} \rightarrow \text{DISTR. DI ERLANG } f(t \mid E_{RLANG}(k,r))$$

$\downarrow$ $m = x-1$

TEOREMA

$$E[t] = \frac{k}{r} = k\tau \qquad Var[t] = \frac{k}{r^2} = k\tau^2 \rightarrow \sigma(t) = \sqrt{k}\,\tau$$

ESEMPI: $k=1 \rightarrow f(t \mid E_{RLANG}(k=1, r)) = r e^{-rt}$ → ESPONENZIALE

$k=2 \rightarrow f(t \mid E_{RLANG}(k=2, r)) = r^2 t\, e^{-rt}$

...

DISTRIBUZIONE DI POISSON

- DERIVIAMO UNA NUOVA PDF, ANCH'ESSA INTRINSECAMENTE BINOMIALE:

$$\lim_{\substack{n\to\infty \\ p\to 0}} B_{n,p}(x) = P_\lambda(x) \qquad (\lambda = np) \rightarrow \text{NUOVO PARAMETRO PER DEFINIRE POISSONIANA}$$

$$p \doteq \frac{\lambda}{n}$$

$$\lim_{\substack{n\to\infty \\ p\to 0}} \frac{n!}{x!\,(n-x)!}\, p^x (1-p)^{n-x} = \lim_{\substack{n\to\infty \\ p\to 0}} \frac{n!}{x!\,(n-x)!}\, \frac{\left(\frac{\lambda}{n}\right)^x \left(1-\frac{\lambda}{n}\right)^n}{\left(1-\frac{\lambda}{n}\right)^x} = \left(1-\frac{\lambda}{n}\right)^x \to 1 \text{ NEL LIMITE } \frac{\lambda}{n}\to 0$$

$$= \frac{\lambda^x}{x!} \lim_{\substack{n\to\infty \\ p\to 0}} \frac{n(n-1)(\dots)(n-x+1)}{n^x} \left(1-\frac{\lambda}{n}\right)^n = \frac{\lambda^x}{x!} \lim_{\substack{n\to\infty \\ p\to 0}} \left(\frac{n^x}{n^x} \left(1-\frac{\lambda}{n}\right)^n \right) =$$

$$= \frac{\lambda^x}{x!} \lim_{\substack{n\to\infty \\ p\to 0}} \left(1-\frac{\lambda}{n}\right)^n = \frac{\lambda^x}{x!} e^{-\lambda} \rightarrow \text{DISTR. DI POISSON}$$

- LA DISTR. SCHEMATIZZA MOLTI FENOMENI, PRINCIPALMENTE LEGATI AL CONTEGGIO. IN PARTICOLARE SE CONTO IN UN INTERVALLO Δt SUDDIVISO IN MOLTI δt, IL PROCESSO È POISSONIANO SE:
  1) PROB. DI UN SINGOLO CONTEGGIO IN δt $\propto$ δt
  2) PROB. CONTEGGIO IN δt $\ll$ PROB. DI NON CONTEGGIO IN δt E PROB. DI AVERE PIÙ DI UN CONTEGGIO TRASCURABILE
  3) CONTEGGIO IN δt_1 INDIPENDENTE DAL CONTEGGIO IN δt_2;

- NORMALIZZAZIONE: $\sum_{x=0}^{\infty} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{+\infty} \frac{\lambda^x}{x!} = 1$ (SVILUPPO TAYLOR DI e^λ) ✓

- $E[x \mid P_\lambda] = \sum_{x=0}^{\infty} x \frac{\lambda^x e^{-\lambda}}{x!} = \sum_{x=1}^{\infty} \frac{\lambda^x e^{-\lambda}}{(x-1)!} \overset{k=x-1}{=} \lambda \sum_{k=0}^{+\infty} \frac{\lambda^k e^{-\lambda}}{k!} = \lambda = np$ BINOMIALE MASCHERATA!

- $E[x^2 \mid P_\lambda] = \sum_{x=0}^{\infty} \frac{x^2 \lambda^x e^{-\lambda}}{x!} = \lambda \sum_{x=1}^{\infty} x \frac{\lambda^{x-1} e^{-\lambda}}{(x-1)!} = \lambda \sum_{k=0}^{\infty} (k+1) \frac{\lambda^k e^{-\lambda}}{k!} =$

$$= \lambda \left(\sum_{k=0}^{\infty} \frac{k \lambda^k e^{-\lambda}}{k!} + \sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} \right) = \lambda(\lambda+1)$$

- $\mathrm{VAR}[x \mid P_\lambda] = \lambda(\lambda+1) - \lambda^2 = \lambda \quad \Rightarrow \quad \sigma(x) = \sqrt{\lambda}$

- NEL LIMITE PER CUI $\lambda \to \infty$ (GRANDE) $\Rightarrow P_\lambda \sim N(\lambda; \sqrt{\lambda})$ PER CUI ANCHE LA POISSONIANA TENDERÀ A SIMMETRIZZARSI (GAUSSIANA)

- PROB. CHE UNA PALLINA CADA NELLA URNA K-ESIMA:

$$P_K = P(K \mid B_{n,p}) = \binom{N}{K} p^K (1-p)^{N-K} \xrightarrow{p=\frac{1}{2}} \binom{N}{K} \left(\frac{1}{2}\right)^N$$

- LA PROBABILITÀ DI OTTENERE UNA CONFIGURAZIONE SPECIFICA, CON PRIOR VAGO:

$$P\left(\vec{m} \mid M^K_{N,\vec{p}}\right) = \underbrace{\frac{M!}{\prod_i^N m_i!}}_{\text{COEF. MULTINOM.}} \prod_K^N \underbrace{\left[\binom{N}{K} p^K (1-p)^{N-K}\right]^{m_K}}_{\text{PROB. CHE NEL BIN K CADA UNA PALLINA}} \quad \leftarrow \text{NUMERO EFFETTIVO DI PALLINE NELLA URNA K} \quad = \mathcal{L}(\vec{p} \mid \vec{m})$$

→ APPLICHIAMO IL METODO DI MASSIMIZZAZIONE DELLA VEROSIMIGLIANZA, MEDIANTE LA $\log(\mathcal{L})$ PER TROVARE LA PROBABILITÀ $\hat{p}$ (PROB. CHE VADA A DESTRA) DATA UNA CERTA CONFIG. DEL PALLINOMETRO DOPO AVER FISSATO LE PALLINE

$$\log \mathcal{L}(\vec{p} \mid \vec{m}) \overset{\text{TAYLOR}}{=} \underbrace{\text{COSTANTE}}_{\sum_K m_K \log\binom{N}{K}} + \sum_{K=0}^N m_K \left[K \log(p) + (N-K)\log(1-p)\right]$$

$$\frac{d \log \mathcal{L}}{dp} = \sum_{K=0}^N m_K \left[\frac{K}{p} - \frac{N-K}{1-p}\right] = \sum_{K=0}^N \frac{K(1-p) - p(N-K)}{p(1-p)} m_K = 0$$

$$\Rightarrow \sum_{K=0}^N \underbrace{\left(K(1-p) - (N-K)p\right)}_{K - Kp - Np + Kp} m_K = \sum_{K=0}^N (K - Np) m_K = 0$$

$$\Rightarrow \sum_{K=0}^N K m_K = Np \underbrace{\sum_{K=0}^N m_K}_{M} \Rightarrow NMp = \sum_{K=0}^N K f_K M \quad \left(f_K = \frac{m_K}{M}\right) \rightarrow \boxed{\hat{p} = \frac{1}{N} \sum_{K=0}^N K f_K}$$

$$\sigma^2(\hat{p}) = -\frac{1}{\frac{d^2 \log \mathcal{L}}{dp^2}} \rightarrow \frac{d^2 \log \mathcal{L}}{dp^2} = \frac{d}{dp}\left(\sum_{K=0}^N m_K \left(\frac{K}{p} - \frac{N-K}{1-p}\right)\right) =$$

$$= -\sum_{K=0}^N m_K \left(\frac{K}{p^2} + \frac{N-K}{(1-p)^2}\right) \Rightarrow \sigma^2(\hat{p}) = \frac{1}{\sum_{K=0}^N m_K \left(\frac{K}{p^2} + \frac{N-K}{(1-p)^2}\right)} = \frac{1}{M \sum_{K=0}^N f_K \left(\frac{K}{p^2} + \frac{N-K}{(1-p)^2}\right)}$$

SE $p \approx 1-p$

$$= \frac{1}{M \sum_{K=0}^N f_K \frac{K+N}{p^2}} = \frac{1}{MN \sum_{K=0}^N \frac{f_K}{p^2}} = \frac{p^2}{MN} \Rightarrow \sigma(\hat{p}) = \frac{\hat{p}}{MN}$$

$\sum_K f_K = 1$

→ L'INCERTEZZA TOTALE DECRESCE ALL'AUMENTARE DEL NUMERO DI PALLINE E DI FILE DI CHIODI

DISUGUAGLIANZA DI MARKOV

- DEFINITA UNA V.C. $X \geq 0$ DI VALORE ASPETTATO $\mu \neq 0$ CONSIDERIAMO UNA SOGLIA $\alpha \in \mathbb{R}^+$ T.C. $\alpha \geq \mu \Rightarrow P(X \geq \alpha) \leq \frac{\mu}{\alpha}$ → COSÌ $\frac{\mu}{\alpha} < 1$ È POSITIVO (PROBABILITÀ)

DIM: $E[x] = \mu = \sum_{i=0}^{n} x_i f(x_i) \geq \sum_{i=k}^{n} x_i f(x_i)$ ($x_i \geq \alpha \ \forall i \geq k$)

$\Rightarrow \sum_{i=k}^{n} x_i f(x_i) \geq \sum_{i=k}^{n} \alpha f(x_i) = \alpha \sum_{i=k}^{n} f(x_i) \overset{\text{DEF. CUMULATIVA}}{=} \alpha P(X \geq \alpha)$

$\Rightarrow \mu \geq \alpha P(X \geq \alpha) \rightarrow P(X \geq \alpha) \leq \frac{\mu}{\alpha}$

DISUGUAGLIANZA DI CEBICEV

- DEFINITA UNA V.C. X CON VALORE ATTESO μ E DEVIAZIONE STANDARD σ, ED UN VALORE MOLTIPLICATIVO $k \geq 1$ VALE: $P(|x-\mu| \geq k\sigma) \leq \frac{1}{k^2}$

DIM: DEFINIAMO $y := (x-\mu)^2 \Rightarrow \begin{cases} E[y] = \mu_y = VAR[X] \text{ PER DEFINIZIONE} \\ \alpha := (k\sigma)^2 \rightarrow \alpha \geq \sigma^2 = \mu_y \text{ PERCHÈ } k \geq 1 \end{cases}$

($y \geq 0$)

LE IPOTESI DI MARKOV SONO RISPETTATE ($Y \geq 0 \quad \alpha \geq \mu_y$) ALLORA:

$P(Y \leq \alpha) \leq \frac{\mu}{\alpha} \Rightarrow P((x-\mu)^2 \geq (k\sigma)^2) \leq \frac{\sigma^2}{k^2\sigma^2} \Rightarrow P(|x-\mu| \geq k\sigma) \leq \frac{1}{k^2}$

TEOREMA DI BERNOULLI

- DATA $X \sim B_{n,p} \Rightarrow \begin{cases} E[x] = np \\ \sigma[x] = \sqrt{npq} \end{cases}$ $f_n = \frac{x}{n} \Rightarrow \begin{cases} E[f_n] = p \\ \sigma[f_n] = \sqrt{\frac{pq}{n}} \end{cases}$

CEBICEV $\Rightarrow P\left(|f_n - p| \geq k\sqrt{\frac{p(1-p)}{n}}\right) \leq \frac{1}{k^2} \Rightarrow$ AL CRESCERE DI n DIVENTA SEMPRE MENO PROBABILE OSSERVARE FREQUENZE RELATIVE CHE DIFFERISCONO MOLTO DA p

INFERENZA POISSONIANA

- SIA $X = x$ LA V.C. DEI CONTEGGI IN UN TEMPO $T = 0 \quad x \to \lambda$

$$f(\lambda \mid x, p) = \frac{\frac{\lambda^x}{x!} e^{-\lambda} f_0(\lambda)}{\int_0^{+\infty} \frac{\lambda^x}{x!} e^{-x} f_0(\lambda) d\lambda} \overset{\text{PRIORI UNIFORME}}{=} \frac{\frac{\lambda^x}{x!} e^{-\lambda}}{\underbrace{\int_0^{+\infty} \frac{\lambda^x}{x!} e^{-x} d\lambda}_{\text{PDF NORMALIZZATA}} = 1} = \frac{\lambda^x e^{-\lambda}}{x!} \to \text{FUNZ. GAMMA}$$

$$f(\lambda) = \gamma(c = x+1, r = 1) = \frac{r^c}{\Gamma(c)} \lambda^{c-1} e^{-r\lambda} = \frac{\lambda^x}{x!} e^{-\lambda}$$

- $E[\lambda] = \frac{c}{r} = x+1$
- $\text{VAR}[\lambda] = \frac{c}{r^2} = x+1$
- $\text{MODA} = \begin{cases} 0 & \text{SE } c < 1 \\ \frac{c-1}{r} & \text{SE } c \geq 1 \end{cases} = x$

SAPENDO ORA $r \overset{\text{RATE}}{=} \frac{\lambda}{T} \Rightarrow \begin{cases} E[r] = \frac{x+1}{T} \\ \text{VAR}[r] = \frac{x+1}{T^2} \end{cases}$

SI OSSERVA INOLTRE CHE PER $x \to +\infty$ $\begin{cases} E[\lambda] = x \\ \text{VAR}[\lambda] = x \\ \lambda \sim N(x, \sqrt{x}) \end{cases}$

CASO CRITICO POISSONIANA

- CASO Ø CONTEGGI

$$f(\lambda \mid x = 0, p) = e^{-\lambda} \Rightarrow F(\lambda \mid x = 0, p) = 1 - e^{-\lambda} \sum_{n=0}^{x} \frac{\lambda^n}{n!} = 1 - e^{-\lambda}$$



- FISSIAMO UN LIMITE SUPERIORE AD UN C.L. DEL 95%

$$F(\lambda) = 1 - e^{-\lambda} = 0{,}95 \Rightarrow e^{-\lambda} = 0{,}05 \Rightarrow \lambda = -\log(0{,}05) \approx 3$$

DISTRIBUZIONE MULTINOMIALE

- NELLA BINOMIALE CI SONO 2 ESITI POSSIBILI. NELLA MULTINOMIALE L'EVENTO PUÒ AVVENIRE SECONDO K MODALITÀ. POSSIAMO PENSARE AD UN ISTOGRAMMA CON K BINS, E QUINDI $n_1 \dots n_K$ VAR. DISCRETE CHE SONO I CONTENUTI DEI BIN. i.c.

→ $\sum_i n_i = N$ (PROVE TOTALI) $\quad \sum_i p_i = 1$ (PER OGNI BIN DEFINIAMO LA PROB. CHE L'EVENTO CADA NEL BIN i-ESIMO)

⇒ SUPPONENDO GLI EVENTI INDIPENDENTI, POSSIAMO DIRE CHE LA PROB. DI UNA CERTA CONFIG. CHE OSSERVIAMO SULL'ISTOGRAMMA È $P_{TOT} \propto p_1^{n_1} \cdot p_2^{n_2} \cdot (\dots) \cdot p_K^{n_K}$

→ IL COEFF. DI PROPORZIONALITÀ È IL FATTORE CHE FA IN MODO CHE L'ORDINE NON CONTI; CIOÈ IL NUMERO DI SEQUENZE CHE PRODUCE LA STESSA CONFIG:

$$\binom{N}{n_1} \cdot \binom{N-n_1}{n_2} \cdot (\dots) = \frac{N!}{n_1!(N-n_1)!} \frac{(N-n_1)!}{n_2!(N-n_1-n_2)!} \frac{(N-n_1-n_2)!}{\dots} (\dots) = \frac{N!}{\prod_i n_i!}$$

⇒ $f(\vec{n} \mid \mathcal{M}^{K}_{N,\vec{p}}) = N! \prod_{i=1}^{K} \frac{p_i^{n_i}}{n_i!}$ (K BIN; N PROVE; $\vec{p}$ PROB. BIN)

- $E[n_i \mid \mathcal{M}^{K}_{N,\vec{p}}] = N p_i$ $\quad$ - $VAR[n_i] = N p_i (1-p_i)$

→ CI SI RENDE FACILMENTE CONTO CHE IL NUMERO DI EVENTI IN CIASCUN BIN È CORRELATO FORTEMENTE CON GLI ALTRI: $cov(x_i, x_j) \neq 0$

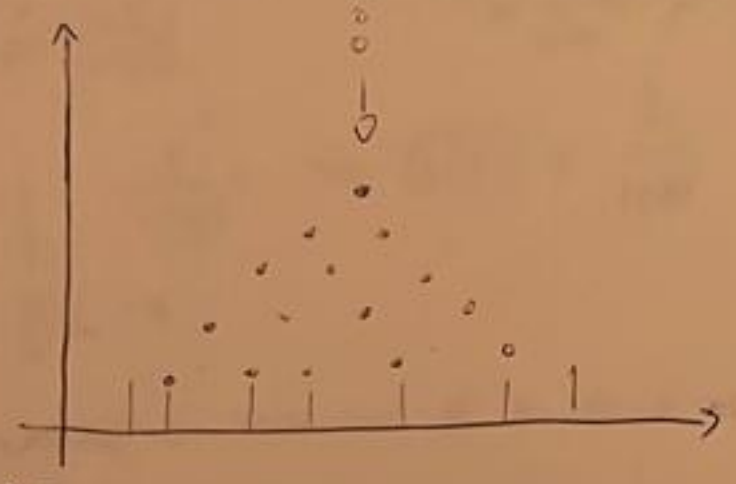
(BASTA PENSARE AL CASO BINOMIALE IN CUI SUCCESSO/INSUCCESSO SONO ANTICORRELATE CON $\rho = -1$)

$$cov(x_i, x_j) = -N p_i p_j \qquad \rho(x_i, x_j) = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}$$

PALLINOMETRO

$p_{dx} = p_{sx} = \frac{1}{2}$

- M PALLINE
- m_i PALLINE NELLA CASELLA i-ESIMA
- N FILE → N+1 CASELLE



→ SI STUDIA LA PROB. CHE PRESA UNA PALLINA, ESSA CADA NELLA CASELLA (BIN) i-ESIMA

$E[m_i] = M p_i$ $\quad VAR[m_i] = M p_i (1-p_i)$ → MULTINOMIALE

p_i RAPPRESENTA LA PROB. DEL SINGOLO BIN → BINOMIALE

$$p_i = \binom{N}{i} p_{dx}^{i} (p_{sx})^{N-i} = \binom{N}{i} \left(\frac{1}{2}\right)^N$$

- FREQUENZA RELATIVA DI SUCCESSO PER UNA CONFIGURAZIONE (PALLINE CHE FINISCONO IN i SUL TOTALE)

$f_i = \frac{m_i}{M}$ ⇒ $E[f_i] = E\left[\frac{m_i}{M}\right] = \frac{1}{M} E[m_i] = p_i$

$VAR[f_i] = \frac{p_i(1-p_i)}{M}$

INFERENZA BINOMIALE

$$f(p \mid B_{n,p}, x) = \frac{\mathcal{L}(x \mid p)\, f_0(p)}{\int_0^1 \mathcal{L}(x \mid p)\, f_0(p)\, dp} \overset{\text{Prior vag}}{=} \frac{\binom{n}{x} p^x (1-p)^{n-x}}{\int_0^1 \binom{n}{x} p^x (1-p)^{n-x} dp} \overset{\substack{x = r-1 \\ n-x = s-1}}{=}$$

$$= \frac{p^x (1-p)^{n-x}}{\underbrace{\int_0^1 p^{r-1} (1-p)^{s-1} dp}_{\text{BETA DI EULERO}}} = \frac{p^x (1-p)^{n-x}}{\Gamma(s)\,\Gamma(r)} \cdot \Gamma(s+r) = \frac{p^x (1-p)^{n-x}\, \Gamma(x+1+n-x+1)}{\Gamma(x+1)\,\Gamma(n-x+1)} =$$

($\Gamma(k) = (k-1)!$)

$$= \frac{p^x (1-p)^{n-x}\,(n+1)!}{x!\,(n-x)!}$$

→ DISTR. BETA $(r = x+1, s = n-x+1)$

→ CALCOLIAMO VALORE ATTESO E VARIANZA

$$E[p] = \frac{r}{r+s} = \frac{x+1}{x+1+n-x+1} = \frac{x+1}{n+2} \xrightarrow{n \to +\infty} \frac{x}{n}$$

(NOTA COME SE I DATI SONO UFFICIALI L'APPROCCIO BAYESIANO = FREQUENTISTA)

$$VAR[p] = \frac{E[p]\, s}{(r+s+1)(r+s)} = \frac{\left(\frac{x+1}{n+2}\right)(n-x+1)}{(n+3)(n+2)} = \frac{(x+1)(n-x+1)}{(n+3)(n+2)^2} = \frac{1}{n+3}\left[\frac{x+1}{n+2}\left(\frac{n+2}{n+2} - \frac{x+1}{n+2}\right)\right]$$

($+1-1$)

$$= \frac{1}{n+3}\left[\frac{x+1}{n+2}\left(1 - \frac{x+1}{n+2}\right)\right] = \frac{1}{n+3} E[p]\,(1 - E[p]) \xrightarrow{n \to +\infty} \sigma(p) = \sqrt{\frac{\frac{x}{n}\left(1 - \frac{x}{n}\right)}{n}}$$

(TENDE A 0)

CASI CRITICI BINOMIALE

- $(x=0)$ $\mathcal{L}(x=0 \mid B_{n,p}) = (1-p)^n \Rightarrow f(p \mid x=0) = (n+1)(1-p)^n$

CONSIDERO QUINDI UN LIMITE SUPERIORE: $F(p) = \int_0^{p'} (n+1)(1-p)^n dp = -(n+1)\frac{(1-p)^{n+1}}{(n+1)}\Big|_0^{p'} = 1 - (1-p')^{n+1}$

IL LIMITE SUPERIORE È LEGATO AL CONFIDENCE LEVEL CHE VOGLIO CONSIDERARE: $p \le p_0$ AL 95% (ESEMPIO)

$$F(p_0 \mid x=0) = 0{,}95 \Rightarrow 1 - (1-p_0)^{n+1} = 0{,}95 \Rightarrow (1-p_0)^{n+1} = 0{,}05 \Rightarrow p_0 = 1 - \sqrt[n+1]{0{,}05}$$

⇒ IL RISULTATO DICENTA: LA PROB. DI OSSERVARE UN EVENTO È INFERIORE DI p_0 AL 98% DI CONF. LEVEL

NOTA: SE $n \to \infty$ $p_0 \to 0$ QUINDI LA PROBABILITÀ (LIMITE) DICENTA SEMPRE PIÙ PICCOLA

- $(x=n)$ $\mathcal{L}(x=n \mid B_{n,p}) = p^n \Rightarrow f(p \mid x=n) = (n+1)\,p^n$

CONSIDERO STAVOLTA UN LIMITE INFERIORE $F(p) = P(p \ge p_0) = \int_{p'}^1 (n+1) p^n dp = (n+1)\frac{p^{n+1}}{(n+1)}\Big|_{p'}^1 = 1 - p^{n+1}$

FISSO ANCHE QUI UN CONFIDENCE LEVEL: $F(p \mid x=n) = 0{,}95$

$\Rightarrow 1 - p_0^{n+1} = 0{,}95 \Rightarrow p_0 = \sqrt[n+1]{0{,}05} \Rightarrow 0 \le p_0 \le p \le 1$ AL 95% DI CONFIDENCE LEVEL

NOTA: QUANDO $n \to \infty$ $p_0 \to 1$ QUINDI LA PROB. LIMITE DICENTA SEMPRE PIÙ GRANDE

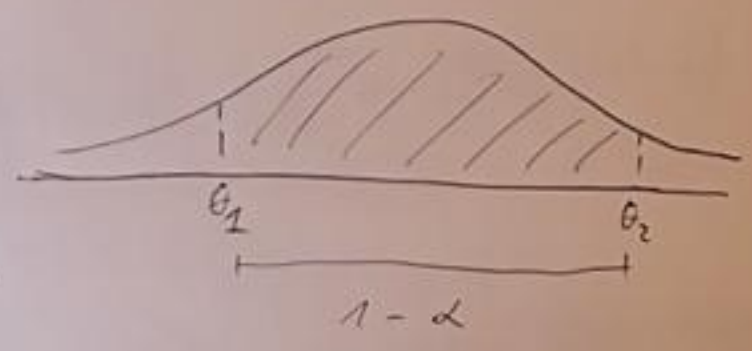
TEST DI IPOTESI

- FARE UN TEST DI IPOTESI SIGNIFICA CONFRONTARE PIÙ IPOTESI PER SCEGLIERE IL MIGLIOR MODELLO TRA QUELLI PLAUSIBILI
- ABBIAMO VISTO CHE CI SONO DIVERSI APPROCCI ALLA PROBABILITÀ : { FREQUENTISTA, BAYESIANO }

APPROCCIO FREQUENTISTA

1) FORMULIAMO UN'IPOTESI H_0 ED EVENTUALI ALTERNATIVE H_i;
2) SI SCEGLIE UNA CERTA FUNZIONE DENSITÀ DI PROBABILITÀ : SI CONSIDERA UNA V.C. ASSOCIATA AI DATI RACCOLTI $\vec{x} = (x_1 \dots x_n) \sim \theta(\vec{x})$. ASSUMENDO VERA L'IPOTESI H_0 CONOSCIAMO LA DISTRIBUZIONE $f(\theta \mid H_0)$
3) FISSIAMO UN INTERVALLO $[\theta_1, \theta_2]$ TALE DA CONTENERE θ CON UNA PROB.

$$P(\theta_1 \le \theta \le \theta_2) = \underbrace{1-\alpha}_{\text{CONFIDENCE LEVEL}} \quad (\text{CON } \underbrace{\alpha}_{\text{SIGNIFICATIVITÀ}} \approx 5\%)$$



α È IL LIVELLO DI SIGNIFICATIVITÀ, CIOÈ LA PROB. DI COMMETTERE UN ERRORE DI 1° TIPO, OVVERO RIFIUTARE H_0 QUANDO ESSA È VERA

$$\alpha = P(\theta_1 \le \theta \le \theta_2) = 1 - \left(P(\theta < \theta_1) + (1 - P(\theta < \theta_2))\right) = P(\theta < \theta_1) + P(\theta < \theta_2)$$

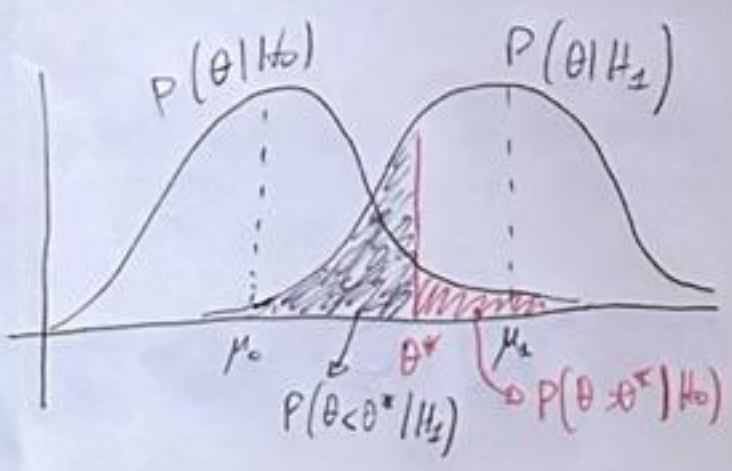
$$\Rightarrow \alpha = P(\theta < \theta_1) + 1 - P(\theta < \theta_2)$$

4) SI FA L'ESPERIMENTO (MISURE) E SI CALCOLA θ_m A PARTIRE DAI DATI, TRAENDO LE CONCLUSIONI — SE $\theta_m \in [\theta_1, \theta_2]$ ACCETTO H_0 ALTRIMENTI LA RIFIUTO

TEST CON PIÙ IPOTESI

- SUPPONIAMO DI AVERE 2 IPOTESI : (COMPATIBILI, QUINDI IN PARTE SOVRAPPOSTE)

$$\begin{cases} H_0 \to \text{VALOR VERO DI } x = \mu_0 \; ; \; f_0(\theta \mid \mu_0) \sim N(\theta \mid \mu_0, \sigma) \\ H_1 \to \text{VALOR VERO DI } x = \mu_1 \; ; \; f_1(\theta \mid \mu_1) \sim N(\theta \mid \mu_1, \sigma) \end{cases}$$



- FISSO θ^* COMPRESO TRA μ_0 E μ_1

$$\begin{cases} P(\theta < \theta^* \mid H_0) = 1 - \alpha \\ P(\theta > \theta^* \mid H_1) = 1 - \beta \to \beta = 1 - P(\theta > \theta^* \mid H_1) = P(\theta < \theta^* \mid H_1) \end{cases}$$

(SE $\theta_m < \theta^*$ PREFERISCO H_0 ALTRIMENTI H_1)

- β È LA PROB. DI NON SCARTARE H_0 QUANDO H_1 È VERA (ERRORE DI 2° TIPO)
- α È LA PROB. DI SCARTARE H_0 QUANDO È VERA
- IL LIKELIHOOD RATIO $\lambda(x) = \dfrac{\mathcal{L}(x \mid H_1)}{\mathcal{L}(x \mid H_0)}$ CI DICE, VISTI I DATI, L'IPOTESI PIÙ PROBABILE

SE CONOSCO PDF(λ), CIOÈ COME SI DISTRIBUISCE λ, DATA L'IPOTESI H_0 VERA :

$$\int_{\lambda^*(\text{soglia})}^{+\infty} \text{PDF}(\lambda)\, d\lambda = \alpha \quad \text{— SE } \lambda_m > \lambda^* \text{ I DATI CI SPINGONO A SCARTARE } H_0 \text{ IN FAVORE DI } H_1$$

COMBINAZIONE DI RISULTATI POISSONIANI

• USANDO BOXES CON PRIOR DATA DA EXP 1 E LIKELIHOOD DALL EXP 2 E ITERATO PER N RISULTATI.

• INTERVALLI DI TEMPO UGUALI (STESSA SORGENTE)

→ n OSSERVAZIONI DI x_i (CONTEGGI), IN INTERVALLI DI TEMPO DI UGUALE DURATA, DELLO STESSO FENOMENO → VOGLIAMO COMBINARE I RISULTATI ASSUMENDO PRIOR $f_0(\lambda)$ VAGA.

PONIAMO $\lambda = rT \in \vec{x} = \{x_1 \dots x_n\}$

$$\Rightarrow f(\lambda|\vec{x}) \propto \prod_i^n \mathcal{L}(x_i|\lambda) = \prod_i^n \lambda^{x_i} e^{-\lambda} = \lambda^{\sum_i x_i} e^{-n\lambda} = \text{POSTERIOR}$$

NOTIAMO CHE $\lambda \sim f(\lambda|\vec{x}) = \gamma(c = \sum_i x_i + 1, r = n)$

$$\Rightarrow E[\lambda] = \frac{c}{r} = \frac{\sum_i x_i + 1}{n} \qquad \sigma[\lambda] = \frac{\sqrt{c}}{r} = \sqrt{\frac{\sum_i x_i + 1}{n^2}} = \sqrt{\frac{E[\lambda]}{n}}$$

SE $\sum_i x_i = x_{TOT} \gg 1 \Rightarrow f(\lambda) \sim \mathcal{N}\left(\frac{x_{TOT}}{n}; \sqrt{\frac{E[\lambda]}{n}}\right)$

• INTERVALLI DI TEMPO DIVERSI (STESSA SORGENTE)

→ $\begin{cases} \vec{x} = \{x_1 \dots x_n\} \\ \vec{T} = \{T_1 \dots T_n\} \end{cases} \Rightarrow \lambda_i = rT_i$ CON r COSTANTE → FACCIO INFERENZA SULLA RATE

$$f(r|\vec{x},\vec{T}) \propto \prod_i^n (rT_i)^{x_i} e^{-rT_i} \propto r^{\sum x_i} e^{-r\sum T_i}$$

(QUESTI T_i SI CANCELLANO CON L'INTEGRALE AL DEN.)

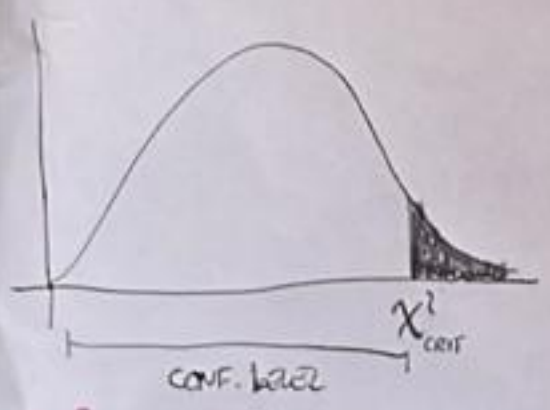
$r \sim \gamma(c = \sum_i x_i + 1; R = \sum_i T_i)$ → APPROX GAUSSIANA

$$\begin{cases} E[r] = \frac{c}{R} = \frac{x_{TOT}+1}{T_{TOT}} \xrightarrow{x_{TOT} \gg 1} \frac{x_{TOT}}{T_{TOT}} \\ \sigma[r] = \sqrt{\frac{c}{R^2}} = \frac{\sqrt{x_{TOT}+1}}{T_{TOT}} \longrightarrow \frac{\sqrt{x_{TOT}}}{T_{TOT}} \end{cases}$$

→ AI FINI DELL'INFERENZA SU r, N MISURE IN N INTERVALLI T_i SONO EQUIVALENTI ALLA SINGOLA MISURA IN T_{TOT}.

TEST DEL χ^2

- SERVE A VALUTARE L'ADEGUATEZZA DELL'ESPERIMENTO CON IL MODELLO TEORICO. FISSATI I GRADI DI LIBERTÀ DEFINISCO IL $\chi^2_{critico}$ PER CUI PER UN VALORE SUPERIORE RIFIUTO L'IPOTESI IN ANALISI AVENDO FISSATO UN C.L.



$$\begin{cases} \text{SE } \chi^2 < \chi^2_{crit} & \text{ACCETTO L'IPOTESI} \\ \text{SE } \chi^2 > \chi^2_{crit} & \text{RIFIUTO L'IPOTESI} \end{cases} \longrightarrow \text{SI FA USANDO LE TABELLE}$$

χ^2 PER UN ISTOGRAMMA

- SUPPONIAMO DI AVERE N MISURE CON CUI COSTRUIAMO UN ISTOGRAMMA
- DEFINIAMO n_i IL NUMERO DI ELEMENTI (MISURE) NEL BIN i-ESIMO

→ EVENTO BINOMIALE: LA MISURA O CADE NEL BIN i-ESIMO O NEL RESTO, QUINDI SO CALCOLARE LA PROB. p_i CHE UNA MISURA CADA NEL BIN i-ESIMO:

$$f_i = \frac{n_i}{N} \longrightarrow \begin{cases} E[n_i] = Np_i \\ VAR[n_i] = Np_i(1-p_i) \end{cases} \longrightarrow \begin{cases} E[f_i] = p_i \\ VAR[f_i] = \frac{p_i(1-p_i)}{N} \end{cases}$$

$$\chi^2_{HIST} = \frac{(f_i - p_i)^2}{\left[\frac{p_i(1-p_i)}{N}\right]} = \frac{(n_i - Np_i)^2}{Np_i(1-p_i)} \overset{\text{PER } p_i \text{ PICCOLE}}{=} \frac{(n_i - Np_i)^2}{Np_i} \qquad \begin{cases} p_i \ll 1 \\ Np_i \gg 10 \end{cases} \Rightarrow$$

$$\chi^2_{TOT} = \sum_i^{N_{BIN}} \frac{(n_i - Np_i)^2}{Np_i}$$

INFERENZA PREDITTIVA

- SUPPONIAMO DI TROVARCI IN UNA CONDIZIONE PER CUI ABBIAMO FATTO UN ESPERIMENTO E LO VOGLIAMO RIPRODURRE. L'EXP PASSATO HA FORNITO UN'INFERENZA CON DISTR. NORMALE DI PARAMETRI x_P, σ_P. L'EXP FUTURO CI SI ASPETTA FINISCA CON x_F E σ_F, ANCH'ESSI IN DISTR. NORMALE:

$$f(x_F|x_P) = \int \underbrace{N(x_F, \sigma_F)}_{\text{LIKELIHOOD NUOVO EXP}} \overbrace{N(x_P, \sigma_P)}^{\text{PRIOR } f(\mu|I)} d\mu = \int \frac{1}{\sqrt{2\pi}\sigma_F} e^{-\frac{(x_F-\mu)^2}{2\sigma_F^2}} \frac{1}{\sqrt{2\pi}\sigma_P} e^{-\frac{(\mu - x_P)^2}{2\sigma_P^2}} d\mu =$$

$$= \frac{1}{\sqrt{2\pi}\sqrt{\sigma_F^2+\sigma_P^2}} e^{-\frac{(x_F-x_P)^2}{2(\sigma_F^2+\sigma_P^2)}} = N\left(x_P, \sqrt{\sigma_P^2+\sigma_F^2}\right) \neq N(x_F, \sigma_F)$$

- ES. PRATICO: N MISURE RIPETUTE NEL PASSATO E NEL FUTURO CON LO STESSO STRUMENTO:

$$\sigma_F = \sigma_P = \frac{\sigma_0}{\sqrt{n}} \Rightarrow \sigma[x_F] = \sqrt{2\left(\frac{\sigma_0^2}{n}\right)} = \sqrt{\frac{2}{n}}\,\sigma_0$$

DISTRIBUZIONE DEL χ^2

- ABBIAMO GIÀ DEFINITO IL χ^2 COME: $\chi^2(\vec{x}\,|\,N(x|\mu;\sigma)] = \sum_i \left[\frac{x_i-\mu(x_i)}{\sigma_i}\right]^2$ E INTRINSECAMENTE COME IL PARAMETRO CHE QUANTIFICA LA BONTÀ DELL'ACCORDO TRA MODELLO E MISURE

→ IL χ^2 HA PDF. CHE DIPENDE DAI GRADI DI LIBERTÀ (ν) DEL SISTEMA:

$$f(x\,|\,\chi^2[\nu]) = \frac{1}{2^{\frac{\nu}{2}}\,\Gamma\left(\frac{\nu}{2}\right)}\; x^{\frac{\nu}{2}-1}\; e^{-\frac{x}{2}} \qquad \text{con} \begin{cases} \Gamma(\nu) = \int_0^{+\infty} e^{-x}\, x^{\nu-1}\, dx \quad \left(\text{GAMMA DI EULERO}\right) \\ x \geq 0 \;\; e \;\; \nu > 0 \;\; (\text{INTERO}) \end{cases}$$

NOTA: PIÙ IN GENERALE DATE k VAR. USUALI INDIPENDENTI, DISTRIBUITE COME NORMALI STANDARDIZZATE VALE $X = \sum_{i=1}^{k} z_i^2$ E $X \sim \chi^2(\nu = k)$ DOVE $z_i = \frac{x-\mu_i}{\sigma_i}$

VALORE ATTESO: $E[x] = \nu$

VARIANZA: $VAR[x] = 2\nu$

● NOTA: $\nu_{TOT} = \sum_i \nu_i = \nu$ $\quad \chi^2(m) + \chi^2(n) = \chi^2(m+n)$

PROPRIETÀ

- CONSIDERIAMO LA VARIANZA CAMPIONARIA: $S_{n-1}^2 = \frac{1}{n-1}\sum_i^n (x_i-\bar{x})^2 \to S_{n-1}^2 \sim \chi^2(\nu = n-1)$

IN PARTICOLARE $S_{n-1}^2 = \frac{\sigma^2}{n-1}\,\chi^2(\nu=n-1)$

$$\begin{cases} E\left[S_{n-1}^2\right] = \frac{\sigma^2}{n-1}\,\nu = \sigma^2 \\ VAR\left[S_{n-1}^2\right] = \frac{\sigma^4}{(n-1)^2}\,2(\nu) = \frac{2\sigma^4}{n-1} \end{cases}$$

- PROVIAMO A CAPIRE E A CONVINCERCI DELLA PRESENZA DI $\frac{1}{n-1}$

$$\sum_i (x_i-\mu)^2 = \sum_i \left[(x_i-\bar{x})+(\bar{x}-\mu)\right]^2 = \sum_i (x_i-\bar{x})^2 + 2\sum_i (\bar{x}-\mu)(x_i-\bar{x}) + \sum_i (\bar{x}-\mu)^2$$

MA $\begin{cases} 2(\bar{x}-\mu)\sum_i (x_i-\bar{x}) = 0 \;\; \text{IN QUANTO } \bar{x} = \frac{\sum_i x_i}{n} \\ \sum_i (\bar{x}-\mu)^2 = n(\bar{x}-\mu)^2 \end{cases}$

$$\sum_i (x_i-\mu)^2 = \sum_i (x_i-\bar{x})^2 + n(\bar{x}-\mu)^2$$

DIVIDO PER σ^2 $\Rightarrow$

$$\underbrace{\sum_i \left(\frac{x_i-\mu}{\sigma}\right)^2}_{\chi^2 \text{ CON } n \text{ GDL}} = \underbrace{\sum_i \left(\frac{x_i-\bar{x}}{\sigma}\right)^2}_{\frac{S_{n-1}^2(n-1)}{\sigma^2}} + \underbrace{\frac{n}{\sigma^2}(\bar{x}-\mu)^2}_{\chi^2 \text{ CON } 1 \text{ GDL}}$$

$\Rightarrow$ PER DIFFERENZA, IL TERMINE CENTRALE DEVE AVERE $n-1$ GDL E DEVE DISTR. COME χ^2

$$\rightarrow \quad S_{n-1}^2 = \frac{\sigma^2}{n-1}\,\chi^2(b = n-1)$$